

Conception Fonctionnelle

Evaluation_Potentiel_Fongique_Interets_Patrimoniaux_CHEGD

Boite Eddy

21 juin 2026

Résumé

Ce document présente, selon une structure IMRaD stricte, la conception fonctionnelle d'un pipeline R complet pour évaluer automatiquement trois indicateurs écologiques par pelouse : le potentiel fongique, l'intérêt patrimonial et le gradient CHEGD avec indice de représentativité IR. Les méthodes décrivent l'ingestion, la normalisation, les calculs métier et le module statistique de fiabilité. Les résultats formalisent les artefacts produits (CSV, figures, synthèses et contrôles QA). La discussion précise l'interprétation, les limites opérationnelles et les conditions de réutilisation du pipeline.

Table des matières

1	Introduction	3
1.1	À propos	3
1.2	Objectifs du pipeline	3
1.3	Dépendances et pré-requis	3
2	Méthodes	4
2.1	Structure du projet	4
2.2	Configuration	5
2.2.1	Résolution des chemins	5
2.3	Structure attendue des données d'entrée	6
2.3.1	Formats acceptés	6
2.3.2	Colonnes obligatoires	6
2.3.3	Formats de dates acceptés	6
2.3.4	Exemple minimal	6
2.4	Pipeline de traitement des données	7
2.4.1	Vue d'ensemble	7
2.4.2	Nettoyage et enrichissement	7
2.4.3	Normalisation de texte	7
2.4.4	Référentiel des sites	7
2.5	Calcul des métriques par site	8
2.5.1	Principe général	8
2.5.2	Potentiel fongique	8
2.5.3	Intérêt patrimonial	9
2.5.4	Gradient CHEGD et Indice de Représentativité (IR)	9
2.6	Module statistique — Analyse de la fiabilité des déterminations	10
2.6.1	Préparation des données de fiabilité	10
2.6.2	Objectif 1 — Analyse descriptive	11
2.6.3	Objectif 2 — Sélection du schéma de pondération optimal	11
2.6.4	Objectif 3 — Sélection du meilleur modèle prédictif de la fiabilité	12
2.6.5	Objectif 4 — Test d'inférence : dépendance fiabilité × site	13
2.6.6	Synthèse du module fiabilité	13

3	Résultats	13
3.1	Résumés descriptifs	13
3.2	Contrôle qualité des données (QA)	14
3.3	Figures produites	14
3.3.1	Figure 1 — Tableau de bord des pelouses	14
3.3.2	Figure 2 — Positionnement écologique	14
3.3.3	Figure 3 — Composition du potentiel fongique	14
3.3.4	Figure 4 — Gradient CHEGD par visite	14
3.3.5	Figure 5 — Heatmap des classes	15
3.3.6	Figure 6 — Niveaux de fiabilité	15
3.3.7	Figure 7 — Indice de Représentativité par visite	15
3.4	Sorties générées — vue d’ensemble	15
3.4.1	Fichiers CSV	15
3.4.2	Figures	16
3.5	Système de logging	17
4	Discussion	17
4.1	Interprétation des indicateurs	17
4.1.1	Score de potentiel fongique	17
4.1.2	Indice patrimonial	18
4.1.3	Gradient CHEGD moyen	18
4.1.4	IR moyen	18
4.1.5	Lecture conjointe des figures 1 et 2	18
4.2	Limites et perspectives	18
4.3	Dépannage (FAQ)	18
	Annexe — Quick Start	19
	Glossaire	20
	Références	20
	Contact et versionnement	20

1 Introduction

Ce document suit une structure IMRaD stricte afin de distinguer clairement le contexte, les méthodes, les résultats produits et la discussion des limites. L'introduction précise le périmètre fonctionnel du pipeline, son objet écologique et les pré-requis d'exécution.

1.1 À propos

Ce document décrit la spécification fonctionnelle complète du script :

```
scripts/Evaluation_Potentiel_Fongique_Interets_Patrimoniaux_CHEGD.R
```

Le script a été conçu pour automatiser l'évaluation mycologique de pelouses en s'appuyant sur la méthode CHEGD (**C**lavaria, **H**ygrocye/Cuphophyllus, **E**ntoloma, **G**eoglossaceae, **D**ermoloma), qui constitue un indicateur de référence pour l'évaluation de la valeur patrimoniale des prairies en Europe occidentale.

1.2 Objectifs du pipeline

Le pipeline réalise automatiquement, pour chaque site (pelouse) :

1. Lecture et validation d'un fichier de données brutes (Excel **.xlsx** ou CSV).
2. Production de résumés descriptifs globaux (par site, famille, espèce, date, fiabilité).
3. Calcul du **potentiel fongique** : score pondéré par groupe fonctionnel.
4. Calcul de l'**intérêt patrimonial** : indice CHEGD et classification en 5 niveaux.
5. Calcul du **gradient CHEGD** : nombre d'espèces CHEGD par visite.
6. Calcul de l'**Indice de Représentativité (IR)** par visite et par site.
7. Génération de 7 figures de synthèse (PNG 300 dpi + PDF vectoriel).
8. Module statistique : analyse de la fiabilité des déterminations (4 objectifs).
9. Export de tous les résultats en fichiers CSV encodés UTF-8.

1.3 Dépendances et pré-requis

Table 1: Packages R requis

Package	Rôle
readxl	Lecture des fichiers Excel (.xlsx)
dplyr	Manipulation de tableaux (filtrage, jointures, agrégations)
stringr	Traitements de chaînes (regex, normalisation, extraction)
ggplot2	Génération des figures
gridExtra	Assemblage de graphiques multi-panneaux
MASS	Régression ordinale (polr) pour le module fiabilité
nnet	Régression multinomiale (multinom) pour le module fiabilité

Les packages requis sont installés automatiquement au démarrage si absents.

Table 2: Packages R optionnels

Package	Utilisation
ggrepel	Gestion automatique des chevauchements de labels (Figure 2)

2 Méthodes

Les méthodes décrivent les choix fonctionnels nécessaires à la reproductibilité du pipeline : organisation du projet, configuration, structure des données, transformations, métriques et module statistique.

2.1 Structure du projet

```

statistics/
+-- data/
|   \-- donnees_recoltes_chegd_pelouses.csv    # Donnees d'entree (configurable)
+-- docs/
|   \-- Evaluation_Potentiel_Fongique_CHEGD_Conception_Fonctionnelle.tex
+-- results/
|   \-- EPFIP_CHEGD/                                # Repertoire de sortie fixe
|       +-- donnees_brutes_nettoyees.csv
|       +-- resume_par_site.csv
|       +-- resume_par_famille.csv
|       +-- resume_par_espece.csv
|       +-- resume_par_date.csv
|       +-- resume_fiabilite_determination.csv
|       +-- potentiel_fongique_par_site.csv
|       +-- indice_patrimonial_par_site.csv
|       +-- gradient_chegd_par_site.csv
|       +-- indice_representativite_ir_par_site.csv
|       +-- synthese_evaluation_par_site.csv
|       +-- resume_global.csv
|       +-- fig1_tableau_de_bord_pelouses.{png,pdf}
|       +-- fig2_positionnement_ecologique.{png,pdf}
|       +-- fig3_composition_potentiel.{png,pdf}
|       +-- fig4_chegd_par_visite.{png,pdf}
|       +-- fig5_heatmap_classes.{png,pdf}
|       +-- fig6_niveaux_fiabilite.{png,pdf}
|       +-- fig7_indice_representativite_ir.{png,pdf}
|       +-- stat_obj1_reliability_distribution.csv
|       +-- stat_obj2_weighting_candidates.csv
|       +-- stat_obj2_best_weighting.csv
|       +-- stat_obj3_best_model_predictions.csv
|       +-- stat_obj3_best_model_confusion_matrix.csv
|       +-- stat_obj3_best_model_coefficients.csv
|       +-- stat_obj4_inference_tests.csv
|       +-- stat_model_selection_summary.csv
|       +-- fig_stat1_reliability_distribution.{png,pdf}
|       +-- fig_stat2_weighting_comparison.{png,pdf}
|       +-- fig_stat3_cv_metrics.{png,pdf}
|       +-- fig_stat3_confusion_matrix_best.{png,pdf}
|       +-- fig_stat3_predicted_probabilities_best.{png,pdf}
|       \-- fig_stat4_site_reliability_heatmap.{png,pdf}
+-- logs/
|   \-- EPFIP_CHEGD_YYYYMMDD_HHMM.log          # Log horodate par execution
+-- scripts/
|   \-- Evaluation_Potentiel_Fongique_Interets_Patrimoniaux_CHEGD.R

```

Convention de nommage

Tous les fichiers générés par ce script sont produits dans le sous-répertoire `results/EPFIP-CHEGD/` (préfixe configurable via `output_prefix`). L'absence d'horodatage dans le nom du répertoire garantit que les réexecutions **écrasent** les sorties précédentes plutôt que de créer des répertoires versionnés.

2.2 Configuration

La configuration est centralisée dans la fonction `get_embedded_config()`.

Table 3: Paramètres de configuration

Paramètre	Valeur par défaut	Description
<code>input_file</code>	<code>data/donnÃes_rÃcoltes_chegd_pelouses.csv</code>	Chemin du fichier d'entrée
<code>input_sheet</code>	<code>NULL</code>	Feuille Excel (NULL = première feuille)
<code>output_dir</code>	<code>results</code>	Répertoire de base pour les sorties
<code>output_prefix</code>	<code>EPFIP-CHEGD</code>	Préfixe du sous-répertoire de sortie
<code>columns\$species</code>	<code>Espèces</code>	Nom de la colonne espèce
<code>columns\$family</code>	<code>Famille</code>	Nom de la colonne famille
<code>columns\$date</code>	<code>Date</code>	Nom de la colonne date
<code>columns\$count</code>	<code>Nombre d'espèce</code>	Nom de la colonne effectif
<code>columns\$site</code>	<code>Site</code>	Nom de la colonne site
<code>columns\$reliability</code>	<code>Fiabilité détermination</code>	Nom de la colonne fiabilité

2.2.1 Résolution des chemins

Le script résout automatiquement les chemins relatifs selon l'environnement d'exécution, par ordre de priorité :

1. Argument `-file=<chemin>` injecté par `Rscript`.
2. `sys.frames()[[1]]$ofile` : injecté par `source()` ou `RStudio`.
3. `getwd()` : répertoire de travail courant (fallback `VSCo` / console interactive).

Le fichier d'entrée est résolu via une stratégie à **3 niveaux** :

1. **Chemin exact** : `file.exists()` sur le chemin résolu.
2. **Correspondance normalisée** : comparaison après suppression des accents, mise en minuscules et retrait des caractères non alphanumériques.
3. **Distance de Levenshtein** (`adist`) : candidat le plus proche si la distance est inférieure au seuil $\max(3, \lfloor 0,25 \times \text{long}(\text{nom}) \rfloor)$.

2.3 Structure attendue des données d'entrée

2.3.1 Formats acceptés

- **Excel** (`.xlsx`) : lu via `readxl::read_excel()`, avec sélection optionnelle de feuille.
- **CSV** : séparateur auto-déTECTÉ (compares le nombre de ; et , sur les 5 premières lignes). Les lignes ne contenant que des séparateurs sont éliminées. Le BOM et les colonnes vides de bord sont supprimés.

2.3.2 Colonnes obligatoires

Table 4: Colonnes requises dans le fichier d'entrée (noms configurables)

Clé config	Nom par défaut	Description
<code>species</code>	Espèces	Nom scientifique de l'espèce
<code>family</code>	Famille	Famille taxonomique
<code>date</code>	Date	Date de l'observation
<code>count</code>	Nombre d'espèce	Nombre d'individus ou d'occurrences
<code>site</code>	Site	Identifiant du site (ex : « Pelouse 3 »)
<code>reliability</code>	Fiabilité détermination	Niveau de confiance dans la détermination

2.3.3 Formats de dates acceptés

Le script tolère les formats suivants, dans l'ordre de tentative :

- Numéro de série Excel (origine 1899-12-30).
- YYYY-MM-DD, DD/MM/YYYY, DD-MM-YYYY, MM/DD/YYYY, DD.MM.YYYY.

Les valeurs vides, NA et NaN sont remplacées par NA avant conversion.


2.3.4 Exemple minimal

Table 5: Exemple de jeu de données d'entrée

Site	Date	Espèces	Famille	Nombre	Fiabilité
Pelouse 1	2025-09-12	Hygrocybe coccinea	Hygrophoraceae	2	Certaine
Pelouse 1	2025-09-12	Entoloma conferendum	Entolomataceae	1	Probable
Pelouse 3	2025-09-20	Clavaria fragilis	Clavariaceae	3	Certaine
Pelouse 3	2025-09-20	Cuphophyllus pratensis	Hygrophoraceae	1	Certaine

2.4 Pipeline de traitement des données

2.4.1 Vue d'ensemble



2.4.2 Nettoyage et enrichissement

Après lecture, les colonnes suivantes sont ajoutées au tableau brut :

- `date_obs` : conversion robuste de la colonne date vers le type `Date`.
- `nombre_espece_num` : conversion de l'effectif en numérique, avec tolérance de la virgule décimale.

2.4.3 Normalisation de texte

La fonction `normalize_text()` est utilisée systématiquement avant toute comparaison de noms d'espèces ou de sites. Elle applique, dans l'ordre :

1. Conversion en chaîne de caractères.
2. Translittération ASCII (`iconv` avec `ASCII//TRANSLIT`).
3. Conversion en minuscules.
4. Remplacement des caractères non alphanumériques par un espace, puis contraction des espaces multiples.

2.4.4 Référentiel des sites

La fonction `prepare_site_reference()` construit un référentiel continu de sites de 1 jusqu'au plus grand identifiant détecté :

- Les identifiants sont extraits avec la regex `d+` depuis les valeurs textuelles (ex : « Pelouse 16 » → 16).
- Les sites non observés dans les données reçoivent un nom synthétique « Pelouse N ».
- Le référentiel garantit que les sites intermédiaires manquants sont inclus dans toutes les métriques.

2.5 Calcul des métriques par site

2.5.1 Principe général

Les trois indicateurs sont calculés dans `build_site_level_metrics()` à partir du tableau dédoublé des espèces par site (`distinct(site_id, species_raw, species_norm, genus, family_norm)`). Seules les **espèces uniques par site** contribuent aux scores (pas de double comptage par visite).

2.5.2 Potentiel fongique

Définition.

Le potentiel fongique est un **score de richesse pondérée** par groupe fonctionnel CHEGD. Il reflète la valeur écologique globale du site en additionnant les contributions de chaque groupe d'espèces indicatrices, pondérées selon leur rareté et leur valeur diagnostique.

Grille de pondération.

Table 6: Pondération des groupes fonctionnels pour le score de potentiel fongique

Groupe	Genres / espèces	Poids	Variable
Mycènes et litière	<i>Mycena</i> , <i>Galerina</i> , <i>Crinipellis</i>	×1	count_litter
Coprophiles	<i>Coprinus</i> , <i>Coprinellus</i> , <i>Conocybe</i> , <i>Panaeolus</i> , <i>Psathyrella</i> , <i>Psilocybe</i> , <i>Stropharia</i> , <i>Coprinopsis</i> , <i>Panaeolina</i>	×1	count_dung
Agarics	<i>Agaricus</i>	×1	count_agaricus
Entolomes	<i>Entoloma</i>	×2	count_entoloma
Clavarioïdes	<i>Clavaria</i> , <i>Clavulinopsis</i> , <i>Ramariopsis</i> + Géoglossacées	×4	count_clavaria
<i>Clavaria zollingeri</i>	espèce seule	×6	count_clavaria_zollingeri
<i>Cuphophyllus</i> spp.	genre entier	×2	count_cuphophyllus
<i>Hygrocybe conica</i>	complexe	×2	count_h_conica
Hygrocybes jaunes	<i>H. chlorophana</i> , <i>H. glutinipes</i> , <i>H. euroflavescens</i>	×2	count_yellow_hygro
<i>H. psittacina</i>	et <i>Gliophorus psittacinus</i>	×2	count_psittacina
<i>C. pratensis</i>	espèce seule	×3	count_c_pratensis
<i>Hygrocybe reidii</i>	espèce seule	×3	count_h_reidii
Hygrocybes rouges	<i>H. coccinea</i> , <i>H. punicea</i> , <i>H. splendidissima</i>	×7	count_red_hygro
<i>H. calyptriformis</i>	et <i>Porpolomopsis calyptriformis</i>	×10	count_h_calyptriformis
<i>Dermoloma</i> spp.	genre entier	×3	count_dermoloma
<i>Camorophyllopsis</i>	genre entier	×3	count_camorophyllopsis
<i>Porpoloma</i> spp.	genre entier	×6	count_porpoloma
Grandes vesses	<i>Langermannia</i> , <i>Calvatia</i>	×1	count_large_caps

Formule.

Score de potentiel fongique

$$\begin{aligned} \text{Score}_{\text{potentiel}} = & n_{\text{litière}} + n_{\text{copro}} + n_{\text{agaricus}} + 2n_{\text{entoloma}} + 4n_{\text{clavaria}} + 6n_{\text{C.zollingeri}} \\ & + 2n_{\text{Cuphophyllus}} + 2n_{\text{H.conica}} + 2n_{\text{hygro.jaunes}} + 2n_{\text{psittacina}} \\ & + 3n_{\text{C.pratensis}} + 3n_{\text{H.reidii}} + 7n_{\text{hygro.rouges}} + 10n_{\text{H.calyptriformis}} \\ & + 3n_{\text{dermoloma}} + 3n_{\text{camarophyllopsis}} + 6n_{\text{porpoloma}} + n_{\text{vesses}} \end{aligned}$$

où n_X est le **nombre d'espèces uniques** du groupe X observées sur le site.

Classification.

Table 7: Classes de potentiel fongique

Seuil	Classe	Couleur recommandée
Score ≤ 10	Potentiel fongique faible	bleu clair (#D8EAF7)
$10 < \text{Score} < 30$	Potentiel fongique intéressant	bleu moyen (#6BAED6)
Score ≥ 30	Potentiel fongique élevé	bleu foncé (#08519C)

2.5.3 Intérêt patrimonial

Définition.

L'intérêt patrimonial est basé sur la **richesse spécifique maximale parmi les 5 groupes CHEGD**. Il reflète le degré de développement du cortège mycologique prairial indicateur.

Groupes CHEGD.

Table 8: Groupes fonctionnels pour l'indice patrimonial (méthode CHEGD)

Lettre	Groupe	Genres inclus
C	Clavarioïdes	<i>Clavaria</i> , <i>Clavulinopsis</i> , <i>Ramariopsis</i>
H	Hygrocybes	<i>Hygrocybe</i> , <i>Cuphophyllus</i> , <i>Gliophorus</i> , <i>Porpolomopsis</i>
E	Entolomes	<i>Entoloma</i>
G	Géoglossacées	Famille <i>Geoglossaceae</i> ; genres <i>Geoglossum</i> , <i>Microglossum</i> , <i>Trichoglossum</i>
D	Dermolomes	<i>Dermoloma</i> , <i>Porpoloma</i> , <i>Camarophyllopsis</i>

Formule.

Indice patrimonial

$$I_{\text{patrimonial}} = \max(n_C, n_H, n_E, n_G, n_D)$$

où n_X est le nombre d'espèces uniques du groupe X sur le site.

Classification en 5 niveaux.

Table 9: Classes d'intérêt patrimonial (inspirées de la méthode CHEGD)

Seuil	Classe	Couleur recommandée
$I \leq 2$	Intérêt faible	vert très clair
$2 < I \leq 5$	Intérêt local	vert clair
$5 < I \leq 10$	Intérêt régional	vert moyen
$10 < I \leq 14$	Intérêt national	vert foncé
$I > 14$	Intérêt international	vert très foncé (#006D2C)

2.5.4 Gradient CHEGD et Indice de Représentativité (IR)

Définition du gradient CHEGD.

Le gradient CHEGD est le **nombre d'espèces CHEGD uniques observées lors d'une visite**. Il est calculé par site et par visite (identifiée par la date de sortie, en l'absence de classeur de référence).

Les espèces CHEGD retenues appartiennent aux genres : *Clavaria*, *Clavulinopsis*, *Ramariopsis*, *Hygrocybe*, *Cuphophyllus*, *Gliophorus*, *Porpolomopsis*, *Entoloma*, *Geoglossum*, *Microglossum*, *Trichoglossum*, *Dermoloma*, *Porpoloma*, *Camarophyllopsis*, ou à la famille *Geoglossaceae*.

Métriques dérivées par site.

Table 10: Métriques CHEGD exportées par site

Colonne	Définition
<code>nb_visites_planifiees</code>	Nombre de visites distinctes (dates)
<code>gradient_visite_N</code>	Nombre d'espèces CHEGD uniques à la visite N
<code>chedg_total</code>	Somme des gradients sur toutes les visites
<code>chedg_moyen</code>	Moyenne des gradients par visite
<code>ir_visite_N</code>	Indice de représentativité à la visite N
<code>ir_moyen</code>	Moyenne des IR par visite

Formule de l'Indice de Représentativité.

Indice de Représentativité (IR) par visite

$$IR_{visite} = \max\left(0, 1 - \frac{G_{visite}}{G_{total}}\right)$$

où :

- G_{visite} : gradient CHEGD de la visite considérée,
- G_{total} : nombre total d'espèces CHEGD distinctes sur l'ensemble des visites du site.

Si $G_{total} \leq 0$, on pose $IR = 0$ (pas de division par zéro).

L'IR moyen par site est la moyenne arithmétique des IR individuels :

$$IR_{moyen} = \frac{1}{V} \sum_{v=1}^V IR_{visite_v}$$

Interprétation de l'IR

- Un IR proche de **1** indique que le gradient d'une visite est faible par rapport au total du site : la visite apporte peu de nouvelles espèces CHEGD (bon signe de suivi avancé).
- Un IR proche de **0** indique que la visite concentre l'essentiel des espèces CHEGD observées.
- L'IR moyen mesure la **régularité de répartition des espèces CHEGD entre les visites**.

2.6 Module statistique — Analyse de la fiabilité des déterminations

Le module fiabilité est orchestré par `run_reliability_objectives()` et exécute quatre objectifs séquentiels. Il opère sur les données enrichies par `prepare_reliability_data()`.

2.6.1 Préparation des données de fiabilité

La fonction `prepare_reliability_data()` enrichit le tableau nettoyé avec :

- `fiabilite` : factor ordonné à 3 niveaux (Non renseignée < Probable < Certaine), issu de la normalisation `normalize_reliability_level()`.
- `month_obs` et `season_obs` : mois et saison dérivés de la date (Hiver / Printemps / Été / Automne).
- `abundance` : effectif numérique (0 si NA).

Normalisation des niveaux de fiabilité.

Table 11: Règles de normalisation des niveaux de fiabilité

Préfixes détectés (après normalisation)	Classe retournée
certain, sur, confirme	Certaine
probable, a verifier, incertain	Probable
Valeur vide, NA, ou non reconnue	Non renseignée

2.6.2 Objectif 1 — Analyse descriptive

But : Décrire la distribution des niveaux de fiabilité dans le jeu de données.

Calcul : Comptage et pourcentage par niveau.

Sortie : `stat_obj1_reliability_distribution.csv`

et `fig_stat1_reliability_distribution.{png,pdf}`.

2.6.3 Objectif 2 — Sélection du schéma de pondération optimal

But : Identifier le schéma de pondération des observations par fiabilité qui maximise la cohérence avec les scores de métriques écologiques.

Schémas évalués :

Table 12: Schémas de pondération candidats

Schéma	w_{Certaine}	w_{Probable}	$w_{\text{Non renseignée}}$
S1	1.0	0.7	0.3
S2	1.0	0.8	0.5
S3	1.0	0.6	0.2

Critère de sélection : Corrélation de rang de Spearman entre le score de référence (potentiel + patrimonial + CHEGD) et le score pondéré par site. Le critère secondaire est le chevauchement des 5 premiers sites entre les deux classements.

Score pondéré par site

$$\text{Score}_{\text{pondéré},s} = \text{Score}_{\text{réf},s} \times \bar{w}_s \quad \text{avec} \quad \bar{w}_s = \frac{1}{n_s} \sum_{i \in s} w_{\text{fiabilite}(i)}$$

Sorties :

- `stat_obj2_weighting_candidates.csv`
- `stat_obj2_best_weighting.csv`
- `fig_stat2_weighting_comparison.{png,pdf}`

2.6.4 Objectif 3 — Sélection du meilleur modèle prédictif de la fiabilité

But : Identifier le modèle statistique prédisant le mieux le niveau de fiabilité d’une observation à partir de ses caractéristiques (site, famille, saison, abondance).

Modèles candidats.

Table 13: Modèles de classification candidats

Identifiant	Modèle	Description
polr	Régression ordinale (<code>MASS::polr</code>)	Tient compte de l’ordre des classes (Non renseignée < Probable < Certaine). Lien logistique (<code>logistic</code>).
multinom	Régression multinomiale (<code>nnet::multinom</code>)	Classes traitées de façon nominale, sans contrainte d’ordre.
baseline_majority	Classifieur majoritaire	Prédit systématiquement la classe la plus fréquente. Sert de référence basse.

Formule des modèles.

$$\text{fiabilite} \sim \text{abundance} + \text{season} + \text{site} + \text{family}$$

Les modalités de site et de famille les moins fréquentes sont regroupées dans une catégorie **Autre** (les 12 modalités les plus fréquentes sont conservées) pour éviter la sur-paramétrisation et les nouvelles modalités sur la partition de test.

Protocole d’évaluation.

Validation croisée $k = 5$ folds, avec stratification aléatoire (`set.seed(42)`). Conditions minimales : au moins 20 observations et au moins 2 classes de fiabilité distinctes.

Métriques d’évaluation.

Table 14: Métriques calculées par modèle et par fold

Métrique	Définition
Accuracy	Proportion de prédictions correctes.
Macro-F1	Moyenne du F1 par classe (précision $\times$ rappel harmonique), pondération uniforme.
Log-loss	$-\frac{1}{n} \sum_i \log p_i^*$ où p_i^* est la probabilité prédite pour la vraie classe. Borné dans $[10^{-15}, 1 - 10^{-15}]$.

Macro-F1

$$F1_{\text{macro}} = \frac{1}{|C|} \sum_{c \in C} F1_c \quad \text{avec} \quad F1_c = \frac{2 \times \text{Précision}_c \times \text{Rappel}_c}{\text{Précision}_c + \text{Rappel}_c}$$

Sélection : Meilleur macro-F1 moyen sur les 5 folds ; en cas d’égalité, meilleure accuracy.

Sorties : matrices de confusion, probabilités prédites, coefficients du modèle final ajusté sur l’ensemble des données, 3 figures.

2.6.5 Objectif 4 — Test d'inférence : dépendance fiabilité × site

But : Tester statistiquement si la répartition des niveaux de fiabilité est indépendante du site d'observation.

Sélection automatique du test.

Table 15: Logique de sélection du test d'inférence

Condition	Test retenu	Identifiant
Toutes les cellules attendues ≥ 5	Chi-2 (<code>chisq.test</code>)	Chi2
Au moins une cellule attendue < 5	Test exact de Fisher	Fisher
Fisher exact échoue (tableau trop grand)	Fisher avec Monte-Carlo ($B = 10000$)	Fisher_simule
Tous les tests échouent	Chi-2 de secours	Chi2_fallback

Hypothèse nulle.

H_0 : La répartition des niveaux de fiabilité est indépendante du site.

Métrique rapportée : $-\log_{10}(p\text{-value})$ pour faciliter les comparaisons (valeur élevée = rejet de l'indépendance).

Sorties : `stat_obj4_inference_tests.csv` + heatmap site × fiabilité.

2.6.6 Synthèse du module fiabilité

Un CSV de synthèse `stat_model_selection_summary.csv` consolide les meilleurs candidats et métriques des 4 objectifs.

3 Résultats

Les résultats correspondent aux artefacts que le pipeline génère de manière reproductible : résumés descriptifs, indicateurs de qualité, figures et fichiers exportés. Ils ne constituent pas une interprétation biologique d'un jeu de données particulier, mais le contrat de sortie attendu du traitement.

3.1 Résumés descriptifs

La fonction `calc_summaries()` produit cinq agrégations indépendantes :

Table 16: Résumés descriptifs produits

Résumé	Fichier CSV	Colonnes calculées
Par site	<code>resume_par_site.csv</code>	<code>nb_lignes</code> , <code>nb_especes_uniques</code> , <code>nb_familles_uniques</code> , <code>abondance_totale</code> , <code>nb_visites</code>
Par famille	<code>resume_par_famille.csv</code>	<code>nb_especes_uniques</code> , <code>abondance_totale</code>
Par espèce	<code>resume_par_espece.csv</code>	<code>nb_observations</code> , <code>abondance_totale</code> , <code>nb_sites</code>
Par date	<code>resume_par_date.csv</code>	<code>nb_observations</code> , <code>nb_especes_uniques</code> , <code>abondance_totale</code>
Fiabilité	<code>resume_fiabilite_determination.csv</code>	<code>fiabilite</code> , <code>nb_observations</code> , <code>pourcentage</code>

Chaque résumé est trié par ordre décroissant de la métrique principale.

3.2 Contrôle qualité des données (QA)

Un bilan de qualité global est exporté dans `resume_global.csv` avec les indicateurs suivants :

- Nombre total de lignes, d'espèces uniques, de familles uniques, d'abondance totale.
- Nombre de sites uniques et de dates uniques.
- Nombre de sites avec potentiel fongique > 10 (« intéressant ou plus »).
- Nombre de sites avec intérêt patrimonial > 2 (« local ou plus »).
- Gradient CHEGD moyen global et IR moyen global.
- Indicateur booléen de **cohérence CHEGD** : vérifie que $\sum_v G_{\text{visite}_v} = G_{\text{total}}$ pour chaque site (tolérance $< 10^{-9}$).

3.3 Figures produites

Toutes les figures sont exportées en **PNG 300 dpi** et en **PDF vectoriel** dans `results/EPFIP-CHEGD/`.

3.3.1 Figure 1 — Tableau de bord des pelouses

Fichier : `fig1_tableau_de_bord_pelouses.{png,pdf}`

Graphique à 3 panneaux horizontaux empilés, un par indicateur :

1. **Panneau haut** : score du potentiel fongique (barres horizontales, couleur par classe).
2. **Panneau milieu** : indice de patrimonialité (barres, couleur par classe patrimoniale).
3. **Panneau bas** : gradient CHEGD moyen (barres, dégradé rouge clair $\rightarrow$ rouge foncé).

Les sites sont triés par rang décroissant de la somme des trois scores.

3.3.2 Figure 2 — Positionnement écologique

Fichier : `fig2_positionnement_ecologique.{png,pdf}`

Nuage de points :

- Axe X : score de potentiel fongique.
- Axe Y : indice de patrimonialité.
- Taille et couleur des points : gradient CHEGD moyen (dégradé rouge).
- Labels (P1, P2...) via `ggrepel` si disponible, sinon décalés géométriquement.
- Lignes pointillées aux seuils : potentiel = 10, patrimonial = 2.

3.3.3 Figure 3 — Composition du potentiel fongique

Fichier : `fig3_composition_potentiel.{png,pdf}`

Barres empilées horizontales : contribution de chaque groupe fonctionnel au score potentiel. Cinq groupes représentés : Cuphophyllus, Hygrocybe (gr. conica), Hygrocybes jaunes, Entoloma, Clavarioïdes. Sites triés par score décroissant.

3.3.4 Figure 4 — Gradient CHEGD par visite

Fichier : `fig4_chegd_par_visite.{png,pdf}`

Barres groupées horizontales : une barre par visite et par site. Sites triés par gradient CHEGD moyen décroissant. Palette de couleur `Set2` (daltonien-compatible).

3.3.5 Figure 5 — Heatmap des classes

Fichier : `fig5_heatmap_classes.{png,pdf}`

Heatmap décisionnelle $3 \times N_{\text{sites}}$:

- Colonnes : Potentiel fongique, Intérêt patrimonial, Gradient CHEGD.
- Couleur : dégradé jaune pâle → vert foncé selon le niveau numérique (1 à 5).
- Annotation textuelle du nom de la classe dans chaque cellule.
- Sites triés par signal total décroissant (niveau pot + niveau pat + niveau chegd).

3.3.6 Figure 6 — Niveaux de fiabilité

Fichier : `fig6_niveaux_fiabilite.{png,pdf}`

Barres horizontales : distribution des niveaux de fiabilité de détermination. Les observations « Non renseignée » sont colorées en rouge pour signaler les données potentiellement moins fiables.

3.3.7 Figure 7 — Indice de Représentativité par visite

Fichier : `fig7_indice_representativite_ir.{png,pdf}`

Heatmap visites $\times$ pelouses : chaque cellule affiche la valeur IR (0–1) avec un dégradé rose clair → vert foncé. Sites triés par IR moyen décroissant.

3.4 Sorties générées — vue d’ensemble

3.4.1 Fichiers CSV

`donnees_brutes_nettoyees.csv`

Tableau brut après nettoyage, enrichi de `date_obs` et `nombre_espece_num`.

`resume_par_site.csv`

Résumé par site : lignes, espèces, familles, abondance, visites.

`resume_par_famille.csv`

Résumé par famille taxonomique.

`resume_par_espece.csv`

Résumé par espèce : observations, abondance, sites.

`resume_par_date.csv`

Résumé par date de sortie.

`resume_fiabilite_determination.csv`

Distribution des niveaux de fiabilité.

`niveaux_fiabilite_rencontres.csv`

Alias de compatibilité pour les niveaux de fiabilité rencontrés.

`potentiel_fongique_par_site.csv`

Score, classe et détail par groupe fonctionnel.

`indice_patrimonial_par_site.csv`

Indices par groupe CHEGD, indice global et classe.

`gradient_chegd_par_site.csv`

Gradient CHEGD par visite, total, moyen et IR.

`indice_representativite_ir_par_site.csv`
 IR par visite et IR moyen.

`synthese_evaluation_par_site.csv`
 Jointure consolidée de toutes les métriques.

`resume_global.csv`
 Indicateurs globaux de qualité et de synthèse.

`stat_obj1_reliability_distribution.csv`
 Distribution des niveaux de fiabilité.

`stat_obj2_weighting_candidates.csv`
 Évaluation des 3 schémas de pondération.

`stat_obj2_best_weighting.csv`
 Meilleur schéma retenu.

`stat_obj3_best_model_predictions.csv`
 Prédictions du meilleur modèle sur tous les folds.

`stat_obj3_best_model_confusion_matrix.csv`
 Matrice de confusion.

`stat_obj3_best_model_coefficients.csv`
 Coefficients du modèle final.

`stat_obj4_inference_tests.csv`
 Résultats du test d'inférence.

`stat_model_selection_summary.csv`
 Synthèse des 4 objectifs.

3.4.2 Figures

`fig1_tableau_de_bord_pelouses`
 3 panneaux : potentiel, patrimonial, CHEGD moyen.

`fig2_positionnement_ecologique`
 Nuage de points : potentiel $\times$ patrimonial, taille = CHEGD.

`fig3_composition_potentiel`
 Barres empilées : groupes fonctionnels par site.

`fig4_chegd_par_visite`
 Barres groupées : gradient CHEGD par visite et par site.

`fig5_heatmap_classes`
 Heatmap décisionnelle 3 indicateurs $\times$ N sites.

`fig6_niveaux_fiabilite`
 Distribution des niveaux de fiabilité.

`fig7_indice_representativite_ir`
 Heatmap IR visites $\times$ pelouses.

`fig_stat1_reliability_distribution`
 Barres : distribution des fiabilités.

`fig_stat2_weighting_comparison`
Comparaison des 3 schémas de pondération.

`fig_stat3_cv_metrics`
Accuracy et Macro-F1 par modèle (CV).

`fig_stat3_confusion_matrix_best`
Matrice de confusion du meilleur modèle.

`fig_stat3_predicted_probabilities_best`
Histogramme des probabilités de confiance.

`fig_stat4_site_reliability_heatmap`
Heatmap site $\times$ fiabilité + résultat test.

3.5 Système de logging

Un fichier log horodaté est créé dans `logs/` à chaque exécution :

`logs/EPFIP_CHEGD_YYYYMMDD_HHMM.log`

Le log inclut :

- Un en-tête avec la version du script, le fichier d'entrée et la configuration.
- Des sections (`log_section()`) balisées par des lignes de séparation.
- Des messages d'info, de warning et d'erreur horodatés.
- Un résumé des données (nombre d'observations, espèces, sites, dates).
- La durée totale d'exécution en pied de log.

Les messages sont simultanément écrits dans le fichier log et affichés dans la console.

4 Discussion

La discussion explicite la portée décisionnelle des indicateurs, les limites méthodologiques et les situations opérationnelles qui nécessitent un contrôle expert.

4.1 Interprétation des indicateurs

4.1.1 Score de potentiel fongique

- **Score ≤ 10 (faible)** : cortège CHEGD peu développé ou mal documenté. Effort d'inventaire ou contexte écologique à vérifier.
- **$10 < \text{Score} < 30$ (intéressant)** : présence d'espèces indicatrices notables ; site à suivre et à protéger.
- **Score ≥ 30 (élevé)** : richesse indicatrice remarquable, intérêt écologique fort ; site prioritaire pour la conservation.

Important

Le score de potentiel est sensible à l'effort d'échantillonnage et à la saison. Un score faible ne signifie pas l'absence d'intérêt, mais peut refléter un inventaire incomplet. Toujours croiser avec l'indice patrimonial et le gradient CHEGD.

4.1.2 Indice patrimonial

- $I \leq 2$: site peu ou pas développé pour les CHEGD.
- $2 < I \leq 5$: intérêt local, richesse CHEGD modérée.
- $5 < I \leq 10$: intérêt régional, pelouse à forte valeur indicatrice.
- $10 < I \leq 14$: intérêt national, site exceptionnel à conserver en priorité.
- $I > 14$: intérêt international, richesse CHEGD exceptionnelle.

4.1.3 Gradient CHEGD moyen

Un gradient CHEGD élevé par visite signale une pression de CHEGD constante sur les visites : la pelouse héberge un cortège CHEGD abondant et régulièrement exprimé. Un gradient faible peut indiquer soit une faible richesse CHEGD, soit une forte saisonnalité.

4.1.4 IR moyen

- IR proche de 1 sur toutes les visites : les espèces CHEGD sont bien réparties entre les visites — signe d'un suivi équilibré ou d'une forte richesse totale.
- IR faible sur une visite : cette visite concentre une grande partie du pool CHEGD du site.
- IR moyen global élevé : bonne représentativité globale du suivi.

4.1.5 Lecture conjointe des figures 1 et 2

La Figure 1 permet une lecture rapide et comparative par site sur les 3 dimensions. La Figure 2 révèle les **profils écologiques** :

- Sites en haut à droite : forte valeur patrimoniale et potentiel élevé (sites prioritaires).
- Sites en bas à gauche : faible valeur sur les deux axes (à renforcer en effort ou à contextualiser).
- Points gros et rouges : gradient CHEGD élevé — sites à enjeu fort de suivi.

4.2 Limites et perspectives

La portée des indicateurs dépend directement de la qualité taxonomique, de l'effort d'échantillonnage, de la saisonnalité et de la complétude des visites. Un score faible ne doit pas être interprété comme une absence d'intérêt écologique sans vérification du contexte de prospection. Les évolutions prioritaires concernent la validation sur plusieurs campagnes, l'ajout de diagnostics d'effort d'inventaire et la documentation systématique des changements méthodologiques dans le journal de versionnement.

4.3 Dépannage (FAQ)

Le script ne trouve pas le fichier d'entrée. Vérifier qu'un fichier `.xlsx` ou `.csv` est présent dans `data/`. Le nom est résolu par correspondance normalisée : les accents et la casse ne sont pas bloquants. Consulter les messages `info` dans la console pour identifier le fichier retenu.

Colonnes manquantes à l'exécution. Le script lève une erreur explicite listant les colonnes introuvables. Vérifier que les noms de colonnes dans `get_embedded_config()$columns` correspondent exactement aux en-têtes du fichier d'entrée (y compris accents et espaces).

Aucune espèce CHEGD détectée / gradients tous à zéro. Vérifier que les noms d'espèces sont bien en format binomial latin (*Genre espèce*). La normalisation est insensible aux accents mais requiert un espace entre le genre et l'épithète. Contrôler dans `donnees_brutes_nettoyes.csv` les colonnes `species_norm` et `genus`.

Le module fiabilité affiche « insuffisant ». Le module requiert ≥ 20 observations avec au moins 2 niveaux de fiabilité distincts. Si non rempli, les métriques statistiques sont exportées comme NA.

Les figures sont vides ou absentes. Vérifier que `site_metrics$combined` n'est pas vide. Un tableau d'entrée sans identifiant de site numérique (regex `d+`) produira un référentiel de sites vide : toutes les métriques seront nulles.

Incohérence CHEGD signalée dans `resume_global.csv`. L'indicateur `coherence_chegd_gradients_ok` vaut 0 si la somme des gradients par visite diffère du total CHEGD d'au moins 10^{-9} . Cela peut survenir si les dates d'observation comportent des doublons ou des valeurs manquantes.

Annexe — Quick Start

Étape 1 — Préparer les données

Placer le fichier d'observations dans `data/`, par exemple :

```
data/donnees_recoltes_chegd_pelouses.csv
```

Le script tolère les variantes orthographiques et les accents manquants grâce à la résolution normalisée (§ 2.2).

Étape 2 — Configurer (optionnel)

Modifier la fonction `get_embedded_config()` dans le script pour adapter :

- `input_file` : chemin vers le fichier d'entrée.
- `columns` : noms de colonnes si le fichier utilise un autre vocabulaire.

Étape 3 — Lancer l'analyse

Depuis la racine du projet :

```
Rscript scripts/Evaluation_Potentiel_Fongique_Interets_Patrimoniaux_CHEGD.R
```

Ou interactivement sous RStudio / VSCode en ouvrant le script et en l'exécutant.

Étape 4 — Consulter les résultats

Toutes les sorties sont dans :

```
results/EPFIP_CHEGD/
```

Acronyme/terme	Définition
CHEGD	Groupe indicateur des prairies : C lavaria, H ygrocybe/Cuphophyllus, E ntoloma, G eoglossaceae, D ermoloma.
IR	Indice de Représentativité : mesure la proportion de « nouveauté » CHEGD d’une visite par rapport au total du site.
Gradient CHEGD	Nombre d’espèces CHEGD uniques observées lors d’une visite donnée.
Potentiel fongique	Score pondéré de richesse fonctionnelle CHEGD d’un site.
Indice patrimonial	Maximum de la richesse CHEGD parmi les 5 groupes du site.
Polr	Proportional Odds Logistic Regression — régression logistique ordinale (MASS::polr).
Multinom	Régression multinomiale (nnet::multinom).
Macro-F1	Moyenne des F1 individuels par classe, pondération uniforme.
Log-loss	Entropie croisée — mesure la calibration probabiliste d’un classifieur.
QA	Quality Assurance — contrôle de qualité des données.

Glossaire

Références

- Harding, J.S. & al. (2012). *Grassland fungi as biodiversity indicators*.
- Methode CHEGD : Rotheroe, M. & al. (1996). *Waxcap grasslands : an assessment of the British resource*. English Nature Research Reports.
- Cours 24 Inventaires — DU Mycologie 2026 du Professeur Pierre-Arthur Moreau, Université de Lille (UFR3S PHAR).
- Wickham, H. (2016). *ggplot2: Elegant Graphics for Data Analysis*. Springer.
- Venables, W.N. & Ripley, B.D. (2002). *Modern Applied Statistics with S*. Springer. (MASS::polr)
- Ripley, B. (2022). *nnet: Feed-Forward Neural Networks and Multinomial Log-Linear Models*. R package.

Contact et versionnement

Auteur	Eddy Boite
Dépôt GitHub	eddyboite-nat/statistics
Branche	main
Version script	1.0
Date de ce document	21 juin 2026

Pour toute évolution du script, ouvrir une issue dans le dépôt GitHub ou documenter les changements dans le journal `CHANGELOG.md` du projet.