

Conception Fonctionnelle

Evaluation_Potentiel_Fongique_Interets_Patrimoniaux_CHEGD

Boite Eddy

15 juin 2026

Résumé

Ce document formalise la conception fonctionnelle d'un dispositif d'évaluation du potentiel fongique et des intérêts patrimoniaux de pelouses, fondé sur des observations mycologiques. La démarche adopte une logique d'ingénierie des exigences : définition du périmètre, spécification des règles de décision, explicitation des hypothèses et encadrement de la traçabilité. L'objectif est de garantir une interprétation homogène des résultats et une reproductibilité des arbitrages entre sites dans un contexte d'aide à la décision environnementale.

Table des matières

1	Problématique et questions directrices	3
2	Objet du document	3
3	Contexte et finalité	3
4	Cadre conceptuel	3
4.1	Parties prenantes et attentes	3
4.2	Bénéfices attendus	4
5	Périmètre fonctionnel	4
5.1	Fonctions couvertes	4
5.2	Hors périmètre	4
6	Exigences fonctionnelles détaillées	4
6.1	Exigences cœur de calcul	4
6.2	Exigences non fonctionnelles	5
7	Configuration	5
7.1	Paramètres par défaut	5
8	Données d'entrée	5
8.1	Formats supportés	5
8.2	Colonnes métier requises	6
8.3	Contrôles d'entrée	6
8.4	Règles de gestion des données manquantes	6
9	Chaîne de traitement fonctionnelle	6
9.1	Étape 1 — Lecture et préparation	6
9.2	Étape 2 — Résumés descriptifs	6
9.3	Étape 3 — Indicateurs par site	7
9.4	Étape 4 — Alignement de référence (optionnel)	7

9.5	Étape 5 — Module fiabilité (Objectifs 1 à 4)	7
9.6	Étape 6 — Restitution	7
9.7	Lecture méthodologique de la chaîne	7
10	Parcours fonctionnels (cas d'usage)	7
10.1	Cas d'usage nominal — Évaluation complète d'une campagne	7
10.2	Cas d'usage alternatif — Données partielles ou hétérogènes	8
11	Règles métier principales	8
11.1	Potentiel fongique	8
11.2	Intérêt patrimonial	8
11.3	Gradient CHEGD	8
11.4	Indice de représentativité (IR)	8
12	Sorties fonctionnelles	8
12.1	Répertoire résultats	8
12.2	Exports principaux	8
12.3	Table de lecture décisionnelle	9
13	Journalisation et traçabilité	9
13.1	Principe	9
13.2	Emplacement et format	9
14	Gestion des erreurs	9
15	Contrôles qualité	10
16	Hypothèses et limites	10
16.1	Biais potentiels	10
16.2	Validité fonctionnelle	10
17	Gouvernance fonctionnelle et cycle de vie	10
17.1	Versionnement des règles	10
17.2	Rythme de revue	10
17.3	Traçabilité métier minimale	11
18	Critères d'acceptation fonctionnelle	11
18.1	Critères complémentaires de recette	11
19	Références bibliographiques indicatives	11

1 Problématique et questions directrices

La variabilité des observations de terrain, la diversité des contextes écologiques et l'hétérogénéité des niveaux de détermination taxonomique rendent nécessaire un cadre d'évaluation explicite et reproductible.

Le présent document répond aux questions directrices suivantes :

- Comment produire une mesure *comparative* du potentiel fongique entre sites ?
- Comment traduire les composantes CHEGD en niveau d'intérêt patrimonial intelligible ?
- Comment intégrer la fiabilité de détermination sans dégrader l'interprétabilité métier ?
- Comment garantir la traçabilité des résultats pour un usage expert et institutionnel ?

2 Objet du document

Ce document décrit la conception fonctionnelle du script `Evaluation_Potentiel_Fongique_Interets_Patrimoniaux_CHEGD.R`. Il précise les objectifs métier, les entrées/sorties, les règles de calcul, les traitements réalisés, ainsi que les mécanismes de contrôle et de traçabilité.

3 Contexte et finalité

Le script a pour finalité d'évaluer des pelouses à partir d'observations mycologiques, selon trois axes principaux :

- **Potentiel fongique,**
- **Intérêt patrimonial,**
- **Gradient CHEGD et indice de représentativité (IR).**

4 Cadre conceptuel

La conception repose sur trois principes conceptuels :

1. **Principe d'agrégation raisonnée** : les observations élémentaires sont agrégées en indicateurs de site afin de soutenir la comparaison inter-sites.
2. **Principe de hiérarchisation explicite** : les classes (potentiel, intérêt patrimonial) sont définies par des règles explicites et auditable.
3. **Principe d'incertitude intégrée** : la fiabilité de détermination est traitée comme une dimension analytique à part entière.

Il ajoute un module d'analyse de la **fiabilité de détermination** (objectifs 1 à 4), et produit des exports exploitables pour l'analyse et l'aide à la décision.

4.1 Parties prenantes et attentes

- **Écologues et mycologues de terrain** : obtenir une lecture fiable du potentiel des sites et de leur intérêt patrimonial.
- **Coordinateurs d'étude** : comparer les sites entre eux, prioriser les actions de prospection et de conservation.

- **Décideurs (gestionnaires/collectivités)** : disposer d'indicateurs synthétiques, traçables et compréhensibles.
- **Équipe data/statistiques** : garantir reproductibilité, robustesse et non-régression des résultats.

4.2 Bénéfices attendus

- **Standardisation** des évaluations entre campagnes et entre observateurs.
- **Objectivation** de la priorisation des sites via des scores/indices explicites.
- **Transparence** grâce aux logs, exports intermédiaires et indicateurs QA.
- **Capitalisation** des analyses de fiabilité pour améliorer les futures collectes.

5 Périmètre fonctionnel

5.1 Fonctions couvertes

- Lecture de données d'observations (CSV/XLSX).
- Nettoyage et normalisation des variables clés.
- Calcul d'indicateurs de synthèse par site.
- Génération de figures de restitution.
- Analyse multi-objectifs de la fiabilité de détermination.
- Export de résultats tabulaires et graphiques.
- Journalisation (console + fichier log).

5.2 Hors périmètre

- Saisie interactive utilisateur.
- Persistance en base de données.
- API web ou service temps réel.
- Gestion des droits utilisateurs (IAM) et workflow de validation documentaire.
- Géoréférencement cartographique avancé (SIG, tuilage, webmap).

6 Exigences fonctionnelles détaillées

6.1 Exigences cœur de calcul

ID	Exigence	Priorité
EF-01	Le système doit accepter un fichier CSV ou XLSX et résoudre automatiquement le chemin d'entrée lorsque le nom diffère légèrement.	Haute
EF-02	Le système doit vérifier la présence des colonnes métier obligatoires et stopper l'exécution en cas d'absence bloquante.	Haute

EF-03	Le système doit calculer un score de potentiel fongique et attribuer une classe associée pour chaque site.	Haute
EF-04	Le système doit calculer l'indice patrimonial et la classe d'intérêt associée pour chaque site.	Haute
EF-05	Le système doit calculer les gradients CHEGD par visite, total et moyen, avec contrôle de cohérence.	Haute
EF-06	Le système doit calculer l'IR par visite et l'IR moyen de site.	Haute
EF-07	Le système doit produire des exports tabulaires et graphiques dans un répertoire horodaté et structuré.	Haute
EF-08	Le système doit générer des résultats pour les objectifs fiabilité 1 à 4.	Haute
EF-09	Le système doit pouvoir s'aligner sur un classeur de référence lorsque celui-ci est détecté.	Moyenne
EF-10	Le système doit journaliser les étapes clés, warnings et erreurs dans un log lisible.	Haute

6.2 Exigences non fonctionnelles

ID	Exigence	Critère
ENF-01	Reproductibilité : à données identiques et configuration identique, les sorties doivent être identiques (hors horodatage).	100%
ENF-02	Traçabilité : chaque exécution doit produire un log horodaté avec sections principales.	Obligatoire
ENF-03	Lisibilité des sorties : noms de fichiers explicites et stables.	Obligatoire
ENF-04	Tolérance aux données imparfaites : conversion robuste des dates/numériques avec messages de contrôle.	Obligatoire

7 Configuration

La configuration est **embarquée dans le script** via `get_embedded_config()`.

7.1 Paramètres par défaut

Paramètre	Valeur par défaut
<code>input_file</code>	<code>data/données_récoltes_chegd_pelouses.csv</code>
<code>input_sheet</code>	<code>NULL</code>
<code>output_dir</code>	<code>results</code>
<code>output_prefix</code>	<code>EPFIP_CHEGD</code>
<code>columns</code>	Mapping métier : espèce, famille, date, effectif, site, fiabilité

8 Données d'entrée

8.1 Formats supportés

- `.csv` (détection automatique du séparateur),
- `.xlsx` (avec/sans feuille explicitée).

8.2 Colonne métier requises

- Espèces
- Famille
- Date
- Nombre d'espèces
- Site
- Fiabilité détermination

8.3 Contrôles d'entrée

- Vérification de présence des colonnes obligatoires.
- Conversion robuste des dates et numériques.
- Suppression des colonnes techniques parasites (ex. ...14).
- Uniformisation des libellés de fiabilité (casse, espaces, variantes d'écriture).
- Détection des valeurs manquantes critiques et émission d'alertes métier.

8.4 Règles de gestion des données manquantes

- Les lignes sans **site** ou sans **espèce** sont exclues des calculs de score.
- Les dates non parseables sont conservées si possible pour l'agrégation non temporelle, mais signalées dans le log.
- Les effectifs non convertibles sont traités comme manquants et ignorés dans les agrégations nécessitant une mesure quantitative.

9 Chaîne de traitement fonctionnelle

9.1 Étape 1 — Lecture et préparation

1. Résolution du fichier d'entrée (nom exact, normalisé, ou proche).
2. Chargement des données.
3. Nettoyage de structure et conversions de type.

9.2 Étape 2 — Résumés descriptifs

Production de synthèses globales :

- par site,
- par famille,
- par espèce,
- par date,
- par niveau de fiabilité.

9.3 Étape 3 — Indicateurs par site

Le script calcule :

- score et classe de **potentiel fongique**,
- indice et classe d'intérêt **patrimonial**,
- **gradient CHEGD** par visite, total et moyen,
- **indice de représentativité (IR)** par visite et moyen.

9.4 Étape 4 — Alignement de référence (optionnel)

Si un classeur de référence est détecté (feuilles attendues : **Visites sur sites**, **Analyse des résultats**, **Intérêt patrimonial**, **Évaluation CHEGD pelouses**), les sorties sont alignées sur les valeurs de référence pour reproduire les résultats métier attendus.

9.5 Étape 5 — Module fiabilité (Objectifs 1 à 4)

- **Objectif 1** : distribution descriptive des niveaux de fiabilité.
- **Objectif 2** : comparaison de schémas de pondération (corrélation de rang + overlap top 5).
- **Objectif 3** : sélection de modèles prédictifs (CV 5 folds ; ordinal/multinomial/baseline).
- **Objectif 4** : test d'inférence site $\times$ fiabilité (Chi² ou Fisher, avec fallback simulé).

9.6 Étape 6 — Restitution

- Exports CSV de synthèse et de détail.
- Génération de figures (PNG/PDF).
- Écriture d'un résumé de sélection des meilleurs candidats pour les objectifs fiabilité.

9.7 Lecture méthodologique de la chaîne

D'un point de vue académique, la chaîne suit un schéma *ingestion* $\rightarrow$ *transformation* $\rightarrow$ *inférence* $\rightarrow$ *restitution*, classique en sciences des données environnementales. Cette structuration favorise l'isolement des sources d'erreur et la comparaison de versions successives du protocole.

10 Parcours fonctionnels (cas d'usage)

10.1 Cas d'usage nominal — Évaluation complète d'une campagne

1. L'analyste dépose le fichier de collecte dans le dossier **data/**.
2. Le script est exécuté avec la configuration embarquée.
3. Le système valide et prépare les données.
4. Le système calcule les indicateurs par site et les objectifs fiabilité.
5. Le système produit les exports CSV, les figures et le log.
6. L'analyste contrôle **resume_global.csv** et le log pour valider l'exécution.

10.2 Cas d’usage alternatif — Données partielles ou hétérogènes

1. Des colonnes sont mal typées ou partiellement manquantes.
2. Le système tente les conversions robustes et signale les anomalies.
3. Si les colonnes critiques manquent, l’exécution s’arrête proprement avec message explicite.
4. Sinon, l’exécution se poursuit avec avertissements et traçabilité complète.

11 Règles métier principales

11.1 Potentiel fongique

Le score est calculé par pondération de groupes/taxons clés. La classe est affectée selon :

- **faible** si $\text{score} \leq 10$,
- **intéressant** si $10 < \text{score} < 30$,
- **élevé** si $\text{score} \geq 30$.

11.2 Intérêt patrimonial

L’indice est basé sur le maximum des composantes CHEGD (groupes C/H/E/G/D), puis traduit en classe d’intérêt (faible, local, régional, national, international).

11.3 Gradient CHEGD

Le gradient est calculé par visite puis agrégé en total et moyenne. Un contrôle de cohérence est produit entre gradients détaillés et total.

11.4 Indice de représentativité (IR)

L’IR est calculé pour chaque visite selon le modèle du classeur Excel :

$$IR_{visite} = \max \left(0, 1 - \frac{\text{gradient_visite}}{\text{nombre_total}} \right)$$

avec $\text{nombre_total} = \text{chegd_total}$ au niveau du site.

12 Sorties fonctionnelles

12.1 Répertoire résultats

Les sorties sont générées dans :

`results/EPFIP_CHEGD/`

12.2 Exports principaux

- Données nettoyées : `donnees_brutes_nettoyees.csv`
- Résumés : `resume_global.csv`, `resume_par_site.csv`, etc.
- Indicateurs site : `potentiel_fongique_par_site.csv`, `indice_patrimonial_par_site.csv`, `gradient_chegd_par_site.csv`, `indice_representativite_ir_par_site.csv`

- Fiabilité : fichiers `stat_obj1_...`, `stat_obj2_...`, `obj3_...`/`stat_obj3_...`, `stat_obj4_...` et `stat_model_selection_summary.csv`
- Figures : `fig1_...` à `fig7_...` + figures objectives.

12.3 Table de lecture décisionnelle

Sortie	Usage décisionnel principal
<code>resume_par_site.csv</code>	Comparer les sites et identifier les priorités d'inventaire/suivi.
<code>potentiel_fongique_par_site.csv</code>	Cibler les sites à fort potentiel biologique.
<code>indice_patrimonial_par_site.csv</code>	Argumenter les enjeux de conservation patrimoniale.
<code>gradient_chegd_par_site.csv</code>	Suivre la structure CHEGD et sa dynamique entre visites.
<code>indice_representativite_ir_par_site.csv</code>	Évaluer la représentativité relative des observations par site.
<code>stat_model_selection_summary.csv</code>	Justifier le choix du modèle le plus pertinent pour la fiabilité.

13 Journalisation et traçabilité

13.1 Principe

Le script journalise :

- en console,
- dans un fichier log dédié.

13.2 Emplacement et format

`logs/EPFIP_CHEGD_YYYYMMDD_HHMM.log`

Le log contient un en-tête d'exécution, les étapes essentielles, warnings/erreurs, et un pied de page avec durée totale et chemin du log.

14 Gestion des erreurs

- Validation stricte des colonnes d'entrée.
- Arrêt explicite en cas d'incohérence bloquante.
- Encapsulation de l'exécution principale dans `tryCatch` avec journalisation d'erreur.
- Messages de diagnostic orientés action (fichier concerné, variable concernée, correction attendue).

15 Contrôles qualité

Le script produit des indicateurs QA, dont :

- `coherence_chegd_gradients_ok`
- `nb_sites_incoherents_chegd`
- `ir_moyen_global`

Ces éléments permettent un suivi de non-régression sur les calculs CHEGD.

16 Hypothèses et limites

- La qualité des résultats dépend de la qualité des colonnes d'entrée.
- Les valeurs de référence (si présentes) peuvent surcharger les calculs locaux (mode fidélité).
- Les performances des modèles de fiabilité dépendent de la taille et de l'équilibre des classes.
- Les pondérations métier reposent sur des conventions expertes, révisables en comité scientifique.
- Les analyses ne remplacent pas l'expertise naturaliste de terrain ; elles la complètent.

16.1 Biais potentiels

- **Biais d'observation** : effort d'échantillonnage et compétence variable selon observateurs.
- **Biais taxonomique** : groupes plus faciles à identifier pouvant être surreprésentés.
- **Biais temporel** : phénologie et fenêtre de prospection influençant la détectabilité.

16.2 Validité fonctionnelle

La validité fonctionnelle est considérée satisfaisante si les règles produisent des classements stables sous variations mineures de données (robustesse locale) et si les sorties restent interprétables par les experts métier (validité de contenu).

17 Gouvernance fonctionnelle et cycle de vie

17.1 Versionnement des règles

Chaque évolution des seuils, classes ou pondérations doit être versionnée et documentée avec : date d'effet, justification métier et impact attendu sur les indicateurs.

17.2 Rythme de revue

- Revue **mensuelle** en phase active de campagne.
- Revue **de clôture** pour figer les paramètres d'une édition de rapport.

17.3 Traçabilité métier minimale

Chaque lot de résultats validé doit conserver :

- l’empreinte du fichier source (nom, date, taille),
- la date d’exécution,
- le jeu de sorties associé (CSV + figures + log),
- les éventuelles décisions de recalage manuel/externe.

18 Critères d’acceptation fonctionnelle

Le script est considéré conforme si :

1. il s’exécute sans erreur sur le jeu de données cible,
2. il génère les CSV et figures attendus,
3. il produit un log horodaté complet,
4. les indicateurs QA sont présents dans `resume_global.csv`.

18.1 Critères complémentaires de recette

- Les classes de potentiel et d’intérêt patrimonial sont explicables pour au moins 3 sites échantillons.
- Les résultats fiabilité (objectifs 1 à 4) sont présents même en cas de fallback statistique.
- L’écart entre gradients détaillés et total reste nul ou explicité pour tout site signalé.

19 Références bibliographiques indicatives

- ISO/IEC/IEEE 29148:2018. *Systems and software engineering – Life cycle processes – Requirements engineering*.
- Suter, G. W. (2006). *Ecological Risk Assessment*. CRC Press.
- Legendre, P. & Legendre, L. (2012). *Numerical Ecology*. Elsevier.
- Zuur, A. F. et al. (2009). *Mixed Effects Models and Extensions in Ecology with R*. Springer.