

Conception Fonctionnelle

Evaluation_Potentiel_Fongique_Interets_Patrimoniaux_CHEGD

Boite Eddy

16 juin 2026

Résumé

Ce document formalise la conception fonctionnelle d'un dispositif d'évaluation du potentiel fongique et des intérêts patrimoniaux de pelouses, fondé sur des observations mycologiques. La démarche s'inscrit dans une logique d'ingénierie des exigences : définition du périmètre, spécification des règles de décision, explicitation des hypothèses et encadrement de la traçabilité. L'objectif est de garantir une interprétation homogène des résultats ainsi qu'une reproductibilité des arbitrages entre sites dans un contexte d'aide à la décision environnementale.

Table des matières

1 Structuration IMRaD adaptée	4
2 Problématique et questions directrices	4
3 Objet du document	4
4 Contexte et finalité	4
5 Cadre conceptuel	4
6 Ancrage académique et critères de scientificité	5
6.1 Parties prenantes et attentes	5
6.2 Bénéfices attendus	5
7 Périmètre fonctionnel	6
7.1 Fonctions couvertes	6
7.2 Hors périmètre	6
8 Exigences fonctionnelles détaillées	6
8.1 Exigences cœur de calcul	6
8.2 Exigences non fonctionnelles	7
9 Configuration	7
9.1 Paramètres par défaut	7
10 Données d'entrée	7
10.1 Formats supportés	7
10.2 Colonnes métier requises	7
10.3 Contrôles d'entrée	8
10.4 Règles de gestion des données manquantes	8

11 Chaîne de traitement fonctionnelle	8
11.1 Étape 1 — Lecture et préparation	8
11.2 Étape 2 — Résumés descriptifs	8
11.3 Étape 3 — Indicateurs par site	8
11.4 Étape 4 — Alignement de référence (optionnel)	9
11.5 Étape 5 — Module fiabilité (Objectifs 1 à 4)	9
11.6 Spécification statistique fonctionnelle (niveau métier)	9
11.6.1 Objectif 1 — Profil de fiabilité	9
11.6.2 Objectif 2 — Sensibilité aux pondérations	9
11.6.3 Objectif 3 — Performance prédictive	9
11.6.4 Objectif 4 — Association site $\times$ fiabilité	10
11.7 Étape 6 — Restitution	10
11.8 Lecture méthodologique de la chaîne	10
11.9 Convention d'interprétation scientifique	10
12 Parcours fonctionnels (cas d'usage)	10
12.1 Cas d'usage nominal — Évaluation complète d'une campagne	10
12.2 Cas d'usage alternatif — Données partielles ou hétérogènes	11
13 Règles métier principales	11
13.1 Potentiel fongique	11
13.2 Intérêt patrimonial	11
13.3 Gradient CHEGD	11
13.4 Indice de représentativité (IR)	11
14 Sorties fonctionnelles	11
14.1 Répertoire résultats	11
14.2 Exports principaux	11
14.3 Inventaire détaillé des fichiers générés	12
14.3.1 A. Fichiers de base (ingestion et contrôles)	12
14.3.2 B. Fichiers d'indicateurs cœur métier	12
14.3.3 C. Fichiers statistiques détaillés (module fiabilité)	12
14.3.4 D. Fichiers graphiques	13
14.3.5 E. Règles de validation de complétude des sorties	13
14.4 Matrice exigences $\rightarrow$ sorties	13
14.5 Table de lecture décisionnelle	13
15 Journalisation et traçabilité	14
15.1 Principe	14
15.2 Emplacement et format	14
16 Gestion des erreurs	14
17 Contrôles qualité	14
17.1 Niveaux d'acceptabilité statistique suggérés	14
17.2 Lecture multi-niveaux des résultats	15
18 Hypothèses et limites	15
18.1 Biais potentiels	15
18.2 Validité fonctionnelle	15

19 Gouvernance fonctionnelle et cycle de vie	15
19.1 Versionnement des règles	15
19.2 Rythme de revue	15
19.3 Traçabilité métier minimale	16
20 Critères d'acceptation fonctionnelle	16
20.1 Critères complémentaires de recette	16
21 Protocole de base	16
22 Références bibliographiques (style harmonisé)	16

1 Structuration IMRaD adaptée

Afin de faciliter la lecture académique, le document peut être interprété selon une structuration IMRaD adaptée aux documents de conception :

- **Introduction** : problématique, objet, contexte et cadre conceptuel.
- **Méthodes** : exigences, règles métier, chaîne de traitement, hypothèses et contrôles.
- **Résultats** : artefacts générés, sorties statistiques et critères d'acceptation.
- **Discussion** : limites, biais, validité, gouvernance et perspectives d'évolution.

Cette lecture transversale n'altère pas l'organisation fonctionnelle, mais améliore l'alignement avec les standards de rédaction scientifique.

2 Problématique et questions directrices

La variabilité des observations de terrain, la diversité des contextes écologiques et l'hétérogénéité des niveaux de détermination taxonomique rendent nécessaire un cadre d'évaluation explicite et reproductible.

Le document répond aux questions directrices suivantes :

- Comment produire une mesure *comparative* du potentiel fongique entre sites ?
- Comment traduire les composantes CHEGD en niveau d'intérêt patrimonial intelligible ?
- Comment intégrer la fiabilité de détermination sans dégrader l'interprétabilité métier ?
- Comment garantir la traçabilité des résultats pour un usage expert et institutionnel ?

3 Objet du document

Le document décrit la conception fonctionnelle du script [Evaluation_Potentiel_Fongique_Interets_Patrimoniaux_CHEGD.R](#). Il précise les objectifs métier, les entrées/sorties, les règles de calcul, les traitements réalisés, ainsi que les mécanismes de contrôle et de traçabilité.

4 Contexte et finalité

Le script vise l'évaluation de pelouses à partir d'observations mycologiques, selon trois axes principaux :

- **Potentiel fongique**,
- **Intérêt patrimonial**,
- **Gradient CHEGD et indice de représentativité (IR)**.

5 Cadre conceptuel

La conception repose sur trois principes conceptuels :

1. **Principe d'agrégation raisonnée** : les observations élémentaires sont agrégées en indicateurs de site afin de soutenir la comparaison inter-sites.

2. **Principe de hiérarchisation explicite** : les classes (potentiel, intérêt patrimonial) sont définies par des règles explicites et auditable.
3. **Principe d'incertitude intégrée** : la fiabilité de détermination est traitée comme une dimension analytique à part entière.

Il ajoute un module d'analyse de la **fiabilité de détermination** (objectifs 1 à 4), et produit des exports exploitables pour l'analyse et l'aide à la décision.

6 Ancrage académique et critères de scientificité

La présente conception s'inscrit dans une logique de *science reproductible* où l'évaluation ne se limite pas à la production d'indicateurs, mais vise la justification explicite des choix méthodologiques.

Les critères de scientificité mobilisés sont les suivants :

- **Explicabilité** : chaque indicateur est rattaché à une règle de calcul documentée.
- **Reproductibilité** : les mêmes données et paramètres conduisent aux mêmes conclusions analytiques.
- **Auditabilité** : les transformations sont traçables via les artefacts intermédiaires et la journalisation.
- **Robustesse locale** : la stabilité des classements est évaluée sous variations raisonnables de pondération.

6.1 Parties prenantes et attentes

- **Écologues et mycologues de terrain** : obtenir une lecture fiable du potentiel des sites et de leur intérêt patrimonial.
- **Coordinateurs d'étude** : comparer les sites entre eux, prioriser les actions de prospection et de conservation.
- **Décideurs (gestionnaires/collectivités)** : disposer d'indicateurs synthétiques, traçables et compréhensibles.
- **Équipe data/statistiques** : garantir reproductibilité, robustesse et non-régression des résultats.

6.2 Bénéfices attendus

- **Standardisation** des évaluations entre campagnes et entre observateurs.
- **Objectivation** de la priorisation des sites via des scores/indices explicites.
- **Transparence** grâce aux logs, exports intermédiaires et indicateurs QA.
- **Capitalisation** des analyses de fiabilité pour améliorer les futures collectes.

7 Périmètre fonctionnel

7.1 Fonctions couvertes

- Lecture de données d'observations (CSV/XLSX).
- Nettoyage et normalisation des variables clés.
- Calcul d'indicateurs de synthèse par site.
- Génération de figures de restitution.
- Analyse multi-objectifs de la fiabilité de détermination.
- Export de résultats tabulaires et graphiques.
- Journalisation (console + fichier log).

7.2 Hors périmètre

- Saisie interactive utilisateur.
- Persistance en base de données.
- API web ou service temps réel.
- Gestion des droits utilisateurs (IAM) et workflow de validation documentaire.
- Géoréférencement cartographique avancé (SIG, tuilage, webmap).

8 Exigences fonctionnelles détaillées

8.1 Exigences cœur de calcul

ID	Exigence	Priorité
EF-01	Le système doit accepter un fichier CSV ou XLSX et résoudre automatiquement le chemin d'entrée lorsque le nom diffère légèrement.	Haute
EF-02	Le système doit vérifier la présence des colonnes métier obligatoires et stopper l'exécution en cas d'absence bloquante.	Haute
EF-03	Le système doit calculer un score de potentiel fongique et attribuer une classe associée pour chaque site.	Haute
EF-04	Le système doit calculer l'indice patrimonial et la classe d'intérêt associée pour chaque site.	Haute
EF-05	Le système doit calculer les gradients CHEGD par visite, total et moyen, avec contrôle de cohérence.	Haute
EF-06	Le système doit calculer l'IR par visite et l'IR moyen de site.	Haute
EF-07	Le système doit produire des exports tabulaires et graphiques dans un répertoire horodatable et structuré.	Haute
EF-08	Le système doit générer des résultats pour les objectifs fiabilité 1 à 4.	Haute
EF-09	Le système doit pouvoir s'aligner sur un classeur de référence lorsque celui-ci est détecté.	Moyenne

EF-10	Le système doit journaliser les étapes clés, warnings et erreurs dans un log lisible.	Haute
-------	---	-------

8.2 Exigences non fonctionnelles

ID	Exigence	Critère
ENF-01	Reproductibilité : à données identiques et configuration identique, les sorties doivent être identiques (hors horodatage).	100%
ENF-02	Traçabilité : chaque exécution doit produire un log horodaté avec sections principales.	Obligatoire
ENF-03	Lisibilité des sorties : noms de fichiers explicites et stables.	Obligatoire
ENF-04	Tolérance aux données imparfaites : conversion robuste des dates/numériques avec messages de contrôle.	Obligatoire

9 Configuration

La configuration est **embarquée dans le script** via `get_embedded_config()`.

9.1 Paramètres par défaut

Paramètre	Valeur par défaut
<code>input_file</code>	<code>data/données_récoltes_chegd_pelouses.csv</code>
<code>input_sheet</code>	NULL
<code>output_dir</code>	<code>results</code>
<code>output_prefix</code>	<code>EPFIP_CHEGD</code>
<code>columns</code>	Mapping métier : espèce, famille, date, effectif, site, fiabilité

10 Données d'entrée

10.1 Formats supportés

- `.csv` (détection automatique du séparateur),
- `.xlsx` (avec/sans feuille explicitée).

10.2 Colonnes métier requises

- Espèces
- Famille
- Date
- Nombre d'espèces
- Site
- Fiabilité détermination

10.3 Contrôles d'entrée

- Vérification de présence des colonnes obligatoires.
- Conversion robuste des dates et numériques.
- Suppression des colonnes techniques parasites (ex. ...14).
- Uniformisation des libellés de fiabilité (casse, espaces, variantes d'écriture).
- Détection des valeurs manquantes critiques et émission d'alertes métier.

10.4 Règles de gestion des données manquantes

- Les lignes sans **site** ou sans **espèce** sont exclues des calculs de score.
- Les dates non parseables sont conservées si possible pour l'agrégation non temporelle, mais signalées dans le log.
- Les effectifs non convertibles sont traités comme manquants et ignorés dans les agrégations nécessitant une mesure quantitative.

11 Chaîne de traitement fonctionnelle

11.1 Étape 1 — Lecture et préparation

1. Résolution du fichier d'entrée (nom exact, normalisé, ou proche).
2. Chargement des données.
3. Nettoyage de structure et conversions de type.

11.2 Étape 2 — Résumés descriptifs

Production de synthèses globales :

- par site,
- par famille,
- par espèce,
- par date,
- par niveau de fiabilité.

11.3 Étape 3 — Indicateurs par site

Le script calcule :

- score et classe de **potentiel fongique**,
- indice et classe d'**intérêt patrimonial**,
- **gradient CHEGD** par visite, total et moyen,
- **indice de représentativité (IR)** par visite et moyen.

11.4 Étape 4 — Alignement de référence (optionnel)

Si un classeur de référence est détecté (feuilles attendues : **Visites sur sites**, **Analyse des résultats**, **Intérêt patrimonial**, **Évaluation CHEGD pelouses**), les sorties sont alignées sur les valeurs de référence pour reproduire les résultats métier attendus.

11.5 Étape 5 — Module fiabilité (Objectifs 1 à 4)

- **Objectif 1** : distribution descriptive des niveaux de fiabilité.
- **Objectif 2** : comparaison de schémas de pondération (corrélation de rang + overlap top 5).
- **Objectif 3** : sélection de modèles prédictifs (CV 5 folds ; ordinal/multinomial/baseline).
- **Objectif 4** : test d'inférence site $\times$ fiabilité (Chi² ou Fisher, avec fallback simulé).

11.6 Spécification statistique fonctionnelle (niveau métier)

Les objectifs fiabilité sont interprétés selon une logique de *preuve convergente* : aucun indicateur n'est utilisé isolément pour conclure. Les décisions de priorisation de site s'appuient sur un faisceau d'indices statistiques complémentaires.

11.6.1 Objectif 1 — Profil de fiabilité

- **Indicateur principal** : part des observations *Certaine* par site et globalement.
- **Indicateur d'alerte** : part *Non renseignée* supérieure à 20%.
- **Interprétation analytique** : qualifier la robustesse du diagnostic par site avant comparaison inter-sites.

11.6.2 Objectif 2 — Sensibilité aux pondérations

- **Stabilité forte** : $\rho \geq 0.90$ et overlap top-5 $\geq 80\%$.
- **Stabilité modérée** : $0.75 \leq \rho < 0.90$ ou overlap top-5 entre 60% et 80%.
- **Stabilité faible** : $\rho < 0.75$ ou overlap top-5 $< 60\%$.
- **Interprétation analytique** : statuer sur la robustesse des classements face aux choix de poids.

11.6.3 Objectif 3 — Performance prédictive

- **Lecture de Macro-F1** : priorité à l'équité entre classes.
- **Lecture d'Accuracy** : performance globale brute.
- **Lecture de Log-loss** : qualité probabiliste des prédictions.
- **Interprétation analytique** : sélectionner un modèle explicatif de la fiabilité à performance équilibrée entre classes.

11.6.4 Objectif 4 — Association site $\times$ fiabilité

- **Mesure primaire** : $M = -\log_{10}(p)$.
- **Seuils de lecture suggérés** :
 - $M < 1.3$: signal faible,
 - $1.3 \leq M < 2$: signal modéré,
 - $M \geq 2$: signal fort.
- **Interprétation analytique** : détecter les effets de contexte site dans la qualité de détermination.

11.7 Étape 6 — Restitution

- Exports CSV de synthèse et de détail.
- Génération de figures (PNG/PDF).
- Écriture d'un résumé de sélection des meilleurs candidats pour les objectifs fiabilité.

11.8 Lecture méthodologique de la chaîne

D'un point de vue académique, la chaîne suit un schéma *ingestion* $\rightarrow$ *transformation* $\rightarrow$ *inférence* $\rightarrow$ *restitution*, classique en sciences des données environnementales. Cette structuration favorise l'isolement des sources d'erreur et la comparaison de versions successives du protocole.

11.9 Convention d'interprétation scientifique

Dans une perspective académique, les résultats sont lus selon une hiérarchie :

1. **description** (structures de données et distributions),
2. **comparaison** (écarts inter-sites et sensibilité des classements),
3. **inférence** (niveau de signal statistique),
4. **discussion critique** (hypothèses, limites, biais, transférabilité).

12 Parcours fonctionnels (cas d'usage)

12.1 Cas d'usage nominal — Évaluation complète d'une campagne

1. L'analyste dépose le fichier de collecte dans le dossier `data/`.
2. Le script est exécuté avec la configuration embarquée.
3. Le système valide et prépare les données.
4. Le système calcule les indicateurs par site et les objectifs fiabilité.
5. Le système produit les exports CSV, les figures et le log.
6. L'analyste contrôle `resume_global.csv` et le log pour valider l'exécution.

12.2 Cas d’usage alternatif — Données partielles ou hétérogènes

1. Des colonnes sont mal typées ou partiellement manquantes.
2. Le système tente les conversions robustes et signale les anomalies.
3. Si les colonnes critiques manquent, l’exécution s’arrête proprement avec message explicite.
4. Sinon, l’exécution se poursuit avec avertissements et traçabilité complète.

13 Règles métier principales

13.1 Potentiel fongique

Le score est calculé par pondération de groupes/taxons clés. La classe est affectée selon :

- **faible** si $\text{score} \leq 10$,
- **intéressant** si $10 < \text{score} < 30$,
- **élevé** si $\text{score} \geq 30$.

13.2 Intérêt patrimonial

L’indice est basé sur le maximum des composantes CHEGD (groupes C/H/E/G/D), puis traduit en classe d’intérêt (faible, local, régional, national, international).

13.3 Gradient CHEGD

Le gradient est calculé par visite puis agrégé en total et moyenne. Un contrôle de cohérence est produit entre gradients détaillés et total.

13.4 Indice de représentativité (IR)

L’IR est calculé pour chaque visite selon le modèle du classeur Excel :

$$IR_{visite} = \max\left(0, 1 - \frac{\text{gradient_visite}}{\text{nombre_total}}\right)$$

avec $\text{nombre_total} = \text{chegd_total}$ au niveau du site.

14 Sorties fonctionnelles

14.1 Répertoire résultats

Les sorties sont générées dans :

`results/EPFIP_CHEGD/`

14.2 Exports principaux

- Données nettoyées : `donnees_brutes_nettoyees.csv`
- Résumés : `resume_global.csv`, `resume_par_site.csv`, etc.
- Indicateurs site : `potentiel_fongique_par_site.csv`, `indice_patrimonial_par_site.csv`, `gradient_chegd_par_site.csv`, `indice_representativite_ir_par_site.csv`

- Fiabilité : fichiers `stat_obj1_...`, `stat_obj2_...`, `obj3_...`/`stat_obj3_...`, `stat_obj4_...` et `stat_model_selection_summary.csv`
- Figures : `fig1_...` à `fig7_...` + figures objectives.

14.3 Inventaire détaillé des fichiers générés

Le système génère un corpus de fichiers orienté **auditabilité** et **réutilisation analytique**. Les artefacts sont regroupés par finalité.

14.3.1 A. Fichiers de base (ingestion et contrôles)

Fichier	Granularité	Contenu fonctionnel attendu
<code>donnees_brutes_nettoyees.csv</code>	observation	Données harmonisées (types, libellés, exclusions techniques).
<code>resume_global.csv</code>	exécution	Volumétries, QA globaux, indicateurs de cohérence CHEGD/IR.
<code>resume_par_site.csv</code>	site	Synthèse multicritère servant de pivot de lecture décisionnelle.
<code>resume_par_famille.csv</code>	famille	Distribution taxonomique utile au cadrage écologique.
<code>resume_par_espece.csv</code>	espèce	Fréquences/abondances pour lecture naturaliste fine.

14.3.2 B. Fichiers d'indicateurs cœur métier

Fichier	Niveau	Usage principal
<code>potentiel_fongique_par_site.csv</code>	site	Score, classe, justification du potentiel fongique.
<code>indice_patrimonial_par_site.csv</code>	site	Valeur d'indice patrimonial et classe d'intérêt associée.
<code>gradient_chegd_par_site.csv</code>	site/visite	Gradients par visite + total + moyen pour suivi dynamique.
<code>indice_representativite_ir_par_site_visite.csv</code>	site/visite	IR par visite et IR moyen pour lecture de représentativité.

14.3.3 C. Fichiers statistiques détaillés (module fiabilité)

Famille de fichiers	Objectif	Interprétation fonctionnelle
<code>stat_obj1_*.csv</code>	Obj.1	Qualité descriptive de la fiabilité (distribution des niveaux).
<code>stat_obj2_*.csv</code>	Obj.2	Robustesse du classement des sites sous pondérations alternatives.
<code>stat_obj3_*.csv</code> / <code>obj3_*.csv</code>	Obj.3	Performance comparative des modèles prédictifs de fiabilité.
<code>stat_obj4_*.csv</code>	Obj.4	Intensité de l'association site × fiabilité (test d'inférence).

14.3.4 D. Fichiers graphiques

- **Figures cœur métier** : positionnement des sites, classes, gradients, IR.
- **Figures fiabilité** : distribution des classes, comparaison de schémas, performances de modèles, visualisation des signaux d'association.
- **Formats** : PNG pour diffusion rapide, PDF pour intégration rapport et archivage.

14.3.5 E. Règles de validation de complétude des sorties

Un lot est déclaré *complet* si :

1. tous les fichiers de base (A) existent,
2. les 4 familles d'indicateurs cœur métier (B) sont présentes,
3. au moins un fichier par objectif fiabilité (C) est généré,
4. le log de run est disponible dans logs/.

14.4 Matrice exigences → sorties

Exigence	Contrôle de conformité	Artefact de preuve
EF-03	Score potentiel calculé pour chaque site	potentiel_fongique_par_site.csv
EF-04	Classe patrimoniale calculée pour chaque site	indice_patrimonial_par_site.csv
EF-05	Cohérence gradients vi- site/total/moyen	gradient_chegd_par_site.csv + QA global
EF-06	IR visite + IR moyen disponibles	indice_representativite_ir_par_site.csv
EF-08	Objectifs fiabilité 1 à 4 restitués	stat_obj1_*.csv à stat_obj4_*.csv
EF-10	Journalisation complète de l'exécution	logs/EPFIP_CHEGD_*.log

14.5 Table de lecture décisionnelle

Sortie	Usage décisionnel principal
resume_par_site.csv	Comparer les sites et identifier les priorités d'inventaire/suivi.
potentiel_fongique_par_site.csv	Cibler les sites à fort potentiel biologique.
indice_patrimonial_par_site.csv	Argumenter les enjeux de conservation patrimoniale.
gradient_chegd_par_site.csv	Suivre la structure CHEGD et sa dynamique entre visites.
indice_representativite_ir_par_site.csv	Évaluer la représentativité relative des observations par site.

15 Journalisation et traçabilité

15.1 Principe

Le script journalise :

- en console,
- dans un fichier log dédié.

15.2 Emplacement et format

logs/EPFIP_CHEGD_YYYYMMDD_HHMM.log

Le log contient un en-tête d'exécution, les étapes essentielles, warnings/erreurs, et un pied de page avec durée totale et chemin du log.

16 Gestion des erreurs

- Validation stricte des colonnes d'entrée.
- Arrêt explicite en cas d'incohérence bloquante.
- Encapsulation de l'exécution principale dans `tryCatch` avec journalisation d'erreur.
- Messages de diagnostic orientés action (fichier concerné, variable concernée, correction attendue).

17 Contrôles qualité

Le script produit des indicateurs QA, dont :

- `coherence_chegd_gradients_ok`
- `nb_sites_incoherents_chegd`
- `ir_moyen_global`

Ces éléments permettent un suivi de non-régression sur les calculs CHEGD.

17.1 Niveaux d'acceptabilité statistique suggérés

Pour renforcer l'interprétation métier, les seuils suivants sont proposés comme repères de qualité (à adapter en comité scientifique) :

- **Obj.2** : stabilité jugée satisfaisante si $\rho \geq 0.85$.
- **Obj.3** : modèle retenu si Macro-F1 améliore d'au moins 5% la baseline.
- **Obj.4** : signal prioritaire si $M \geq 2$ et effectifs de contingence suffisants.
- **QA global** : aucune incohérence CHEGD non expliquée dans le log final.

17.2 Lecture multi-niveaux des résultats

La restitution peut être structurée en trois niveaux de détail :

1. **Niveau directionnel** : classes de potentiel et d'intérêt patrimonial pour arbitrage rapide.
2. **Niveau expert** : gradients CHEGD/IR et diagnostics fiabilité pour interprétation écologique.
3. **Niveau audit** : logs, fichiers intermédiaires et tables statistiques détaillées.

18 Hypothèses et limites

- La qualité des résultats dépend de la qualité des colonnes d'entrée.
- Les valeurs de référence (si présentes) peuvent surcharger les calculs locaux (mode fidélité).
- Les performances des modèles de fiabilité dépendent de la taille et de l'équilibre des classes.
- Les pondérations métier reposent sur des conventions expertes, révisables en comité scientifique.
- Les analyses ne remplacent pas l'expertise naturaliste de terrain ; elles la complètent.

18.1 Biais potentiels

- **Biais d'observation** : effort d'échantillonnage et compétence variable selon observateurs.
- **Biais taxonomique** : groupes plus faciles à identifier pouvant être surreprésentés.
- **Biais temporel** : phénologie et fenêtre de prospection influençant la détectabilité.

18.2 Validité fonctionnelle

La validité fonctionnelle est considérée satisfaisante si les règles produisent des classements stables sous variations mineures de données (robustesse locale) et si les sorties restent interprétables par les experts métier (validité de contenu).

19 Gouvernance fonctionnelle et cycle de vie

19.1 Versionnement des règles

Chaque évolution des seuils, classes ou pondérations doit être versionnée et documentée avec : date d'effet, justification métier et impact attendu sur les indicateurs.

19.2 Rythme de revue

- Revue **mensuelle** en phase active de campagne.
- Revue **de clôture** pour figer les paramètres d'une édition de rapport.

19.3 Traçabilité métier minimale

Chaque lot de résultats validé doit conserver :

- l’empreinte du fichier source (nom, date, taille),
- la date d’exécution,
- le jeu de sorties associé (CSV + figures + log),
- les éventuelles décisions de recalage manuel/externe.

20 Critères d’acceptation fonctionnelle

Le script est considéré conforme si :

1. il s’exécute sans erreur sur le jeu de données cible,
2. il génère les CSV et figures attendus,
3. il produit un log horodaté complet,
4. les indicateurs QA sont présents dans `resume_global.csv`.

20.1 Critères complémentaires de recette

- Les classes de potentiel et d’intérêt patrimonial sont explicables pour au moins 3 sites échantillons.
- Les résultats fiabilité (objectifs 1 à 4) sont présents même en cas de fallback statistique.
- L’écart entre gradients détaillés et total reste nul ou explicité pour tout site signalé.

21 Protocole de base

Ce pipeline repose sur le protocole proposé par Sellier et collaborateurs :

Sellier, Y. et coll. (s.d.). Évaluation du potentiel fongique et de l’intérêt patrimonial des pelouses. Ressource en ligne : <https://www.mycofrance.fr/wp-content/uploads/2025/05/Bull.-SMF-131-1-2-Y-Sellier-et-coll.pdf>.

Le protocole original définit les groupes CHEGD (Clavaria, Hygrocybe, Entoloma, Geoglossaceae, Dermoloma) et les pondérations de potentiel fongique sur lesquels s’appuie ce pipeline.

22 Références bibliographiques (style harmonisé)

- ISO/IEC/IEEE. (2018). *ISO/IEC/IEEE 29148:2018 – Systems and software engineering – Life cycle processes – Requirements engineering*. ISO.
- Legendre, P., & Legendre, L. (2012). *Numerical ecology* (3rd English ed.). Elsevier.
- Sellier, Y., et coll. (s.d.). *Évaluation du potentiel fongique et de l’intérêt patrimonial des pelouses*. Mycofrance. <https://www.mycofrance.fr/wp-content/uploads/2025/05/Bull.-SMF-131-1-2-Y-Sellier-et-coll.pdf>.
- Suter, G. W. (2006). *Ecological risk assessment* (2nd ed.). CRC Press.
- Zuur, A. F., Ieno, E. N., Walker, N. J., Saveliev, A. A., & Smith, G. M. (2009). *Mixed effects models and extensions in ecology with R*. Springer.