

Conception Technique

Evaluation_Potentiel_Fongique_Interets_Patrimoniaux_CHEGD

Boite Eddy

9 juillet 2026

Résumé

Ce document présente la conception technique d'un pipeline d'analyse mycologique destiné à l'évaluation du potentiel fongique, de l'intérêt patrimonial et de la fiabilité de détermination. La description adopte un cadre d'ingénierie reproductible : architecture, contrats de données, méthodes statistiques, robustesse opérationnelle et critères de qualité. L'objectif est de fournir un protocole techniquement auditable, scientifiquement explicitable et réutilisable pour des campagnes futures.

Table des matières

1	Structuration IMRaD adaptée	4
2	Positionnement méthodologique	4
3	Cadre théorique des choix statistiques	4
4	Objectif technique	4
5	Architecture logicielle	5
5.1	Style d'architecture	5
5.2	Principes de conception	5
5.3	Points d'entrée	5
5.4	Configuration	5
5.5	Mise à jour technique issue des nouveaux commentaires du code	5
5.6	Surcharge de configuration	6
6	Dépendances techniques	6
6.1	Packages R	6
6.2	Comportement d'installation	6
7	Contrats d'entrée et de sortie	6
7.1	Entrées	6
7.2	Sorties	6
7.3	Spécification détaillée des fichiers générés	7
7.3.1	Couche 1 — Ingestion et normalisation	7
7.3.2	Couche 2 — Indicateurs métier consolidés	7
7.3.3	Couche 3 — Sorties statistiques objectives (fiabilité)	7
7.3.4	Couche 4 — Restitution graphique	7
7.3.5	Couche 5 — Observabilité	7
7.4	Convention de nommage	8

8	Modèle de données technique	8
8.1	Schéma logique minimal des observations	8
8.2	Artefacts intermédiaires	8
9	Pipeline technique détaillé	8
9.1	Phase A — Ingestion et normalisation	8
9.1.1	Critères de qualité de données	9
9.2	Phase B — Calculs métier	9
9.2.1	Potentiel fongique	9
9.2.2	Intérêt patrimonial	9
9.2.3	Gradient CHEGD	9
9.2.4	Indice de représentativité (IR)	10
9.3	Phase C — Module fiabilité (Objectifs 1 à 4)	10
9.3.1	Contrôles préalables au module fiabilité	10
9.3.2	Préparation des données fiabilité	10
9.3.3	Objectif 1 — Descriptif	10
9.3.4	Objectif 2 — Schémas de pondération	10
9.3.5	Objectif 3 — Sélection de modèles prédictifs	10
9.3.6	Objectif 4 — Inférence statistique site × fiabilité	12
9.4	Phase D — Visualisation	12
9.5	Contrats graphiques	12
10	Mode autonome (sans dépendance classeur externe)	13
11	Exécution stricte/tolérante et étapes non bloquantes	13
12	Logging et observabilité	13
12.1	Fonctions dédiées	13
12.2	Comportement	13
12.3	Événements clés attendus dans le log	13
13	Robustesse et gestion d’erreurs	14
13.1	Niveaux de protection	14
13.2	Fallbacks notables	14
13.3	Politique de sévérité des anomalies	14
14	Contrôles qualité et non-régression	14
14.1	Indicateurs d’assurance qualité (QA) exportés	14
14.2	Critères techniques d’acceptation	14
14.3	Stratégie de tests recommandée	15
14.4	Matrice de validation des artefacts	15
14.5	Critères de stabilité statistique recommandés	15
14.6	Menaces à la validité	15
15	Complexité et performances (qualitatives)	15
15.1	Pistes d’optimisation	16
16	Sécurité, conformité et exploitation	16
16.1	Sécurité des données	16
16.2	Conformité et bonnes pratiques	16
16.3	Procédure opératoire standard (POS)	16
17	Répliquabilité et transparence scientifique	16
17.1	Spécification d’un manifeste de run (recommandée)	17

18 Évolutions techniques recommandées	17
19 Protocole de base	17
20 Références bibliographiques (style harmonisé)	17
Contact et versionnement	18

1 Structuration IMRaD adaptée

Dans une perspective de publication scientifique, la lecture du document peut être organisée selon le schéma IMRaD, adapté à une documentation technique :

- **Introduction** : positionnement méthodologique, objectifs techniques, périmètre.
- **Méthodes** : architecture, modèles de données, procédures statistiques, protocoles de validation.
- **Résultats** : fichiers générés, métriques, tableaux de validation et critères d’assurance qualité (QA).
- **Discussion** : menaces à la validité, limites de transférabilité, recommandations d’évolution.

Cette grille de lecture vise à renforcer la comparabilité inter-versions et la réutilisation des livrables dans des contextes académiques ou institutionnels.

2 Positionnement méthodologique

Le pipeline relève d’une approche *data-centric* appliquée à l’écologie, où les indicateurs métiers sont construits à partir de transformations successives, puis consolidés par des procédures d’inférence statistique. Deux objectifs sont poursuivis simultanément :

- **validité analytique** (qualité des estimations et des tests),
- **validité opérationnelle** (stabilité des sorties, exploitabilité décisionnelle).

3 Cadre théorique des choix statistiques

Le dispositif repose sur une articulation entre statistique descriptive, modélisation prédictive et inférence fréquentiste. Cette combinaison répond à une double exigence : décrire fidèlement les structures observées et tester formellement la plausibilité des relations entre variables contextuelles.

Dans ce cadre, la sélection des métriques privilégie :

- la **comparabilité inter-runs** (mesures stables et interprétables),
- la **sensibilité aux déséquilibres de classes** (Macro-F1),
- la **capacité explicative** (lecture des effets site/famille/saison),
- la **traçabilité des décisions** (fichiers de synthèse et journalisation).

4 Objectif technique

Le document décrit l’architecture technique du script [scripts/Evaluation_Potentiel_Fongique_Interets_Patrimoniaux_CHEGD.R](#), avec un focus sur :

- la chaîne de traitement de données,
- la logique de calcul des indicateurs métier,
- les modèles statistiques utilisés,
- la robustesse (contrôles, mécanismes de repli, journalisation, QA).

5 Architecture logicielle

5.1 Style d'architecture

Le script suit une architecture **pipeline batch séquentielle**, organisée en modules fonctionnels :

1. Initialisation (packages, configuration embarquée, journalisation),
2. Ingestion/normalisation des données,
3. Calculs métier par site,
4. Module de fiabilité (objectifs statistiques 1 à 4),
5. Génération des exports et visualisations,
6. Finalisation et journalisation.

5.2 Principes de conception

- **Déterminisme** : mêmes entrées + même configuration $\Rightarrow$ mêmes sorties (hors horodatage).
- **Tolérance aux variations de données** : conversions défensives et diagnostics explicites.
- **Traçabilité dès la conception** : chaque phase significative est journalisée.
- **Séparation logique** : ingestion, calcul métier, fiabilité, restitution.

5.3 Points d'entrée

- `main()` : orchestration principale.
- Bloc `tryCatch` final : capture d'erreurs globales + log d'échec.

5.4 Configuration

La configuration est intégrée via `get_embedded_config()` :

```
protocol_scope = CHEGD pelouses
strict         = TRUE
input_file     = data/donn\'ees_r\'ecoltes_chegd_pelouses.csv
output_dir     = results
output_prefix  = EPFIP_CHEGD
columns        = {species, family, date, count, site, reliability}
quality_alert_thresholds = {...}
```

Cette section est désormais alignée sur les commentaires internes du script, qui documentent le rôle de chaque paramètre de configuration et la logique de résolution des chemins relatifs/absolus depuis la racine projet.

5.5 Mise à jour technique issue des nouveaux commentaires du code

Les commentaires détaillés ajoutés dans le script renforcent la lisibilité technique et l'auditabilité. Les points suivants sont explicitement couverts :

- **Contrats de fonctions** : paramètres, stratégie de traitement, valeurs de retour et cas limites.
- **Résolution d'entrée robuste** : correspondance exacte, normalisée, puis rapprochement par distance de Levenshtein.

- **Parsing défensif** : conversions sécurisées des dates et numériques, normalisation textuelle et gestion des valeurs manquantes.
- **Mode autonome CSV-only** : lecture exclusive d'un CSV ; les fonctions de lecture de classeur externe sont neutralisées (retour `NULL`).
- **Observabilité** : journalisation structurée de bout en bout avec fonctions dédiées et traces horodatées.

5.6 Surcharge de configuration

Bien que la configuration soit embarquée, le design prévoit une extension simple vers une surcharge par fichier externe (ex. YAML/JSON) pour :

- les seuils métiers,
- les mappings de colonnes,
- les chemins d'entrée/sortie,
- les paramètres de visualisation.

6 Dépendances techniques

6.1 Packages R

- `dplyr`, `stringr` : transformation/normalisation,
- `ggplot2`, `gridExtra` : visualisation,
- `MASS` : régression ordinaire `polr`,
- `nnet` : régression multinomiale `multinom`.

6.2 Comportement d'installation

Les packages requis sont contrôlés au démarrage. En cas d'absence, le script s'arrête avec une erreur explicite et une commande d'installation suggérée (pas d'installation automatique).

7 Contrats d'entrée et de sortie

7.1 Entrées

Formats supportés : `.csv` (séparateur détecté automatiquement : `;`, `,` ou tabulation). Colonnes obligatoires : espèce, famille, date, effectif, site, fiabilité.

7.2 Sorties

- Répertoire fixe : `results/EPFIP_CHEGD/`
- Organisation automatique en sous-répertoires thématiques : `00_data_prepared`, `10_indices_metiers`, `20_syntheses`, `30_statistiques_modeles`, `40_qa_audits`, `50_figures_metier`, `60_figures_statistiques`
- Logs : `logs/EPFIP_CHEGD_YYYYMMDD_HHMM.log`
- CSV de synthèse : résumés, indicateurs, QA, objectifs fiabilité
- Figures PNG/PDF : `fig1` à `fig7` + figures objectives.

7.3 Spécification détaillée des fichiers générés

Le pipeline produit des artefacts en couches : *ingestion*, *indicateurs métier*, *statistiques avancées*, *visualisations*, *observabilité*. Cette structuration permet d'isoler rapidement une anomalie dans la chaîne de traitement.

7.3.1 Couche 1 — Ingestion et normalisation

Artefact	Type	Rôle technique
donnees_brutes_nettoyees.csv	table plate	Point de vérité post-nettoyage, base de toutes les agrégations.
resume_global.csv	table synthèse	QA global, volumétrie, indicateurs de cohérence et métadonnées de run.

7.3.2 Couche 2 — Indicateurs métier consolidés

Artefact	Clé primaire logique	Variables critiques attendues
potentiel fongique	site	potentiel_score, potentiel_classe
indice patrimonial	site	indice_patrimonial, classe_patrimoniale
gradient CHEGD	site	gradient_visite_*, chegd_total, chegd_moyen
indice de représentativité	site	ir_visite_*, ir_moyen

7.3.3 Couche 3 — Sorties statistiques objectives (fiabilité)

Préfixe	Objectif	Contenu typique
stat_obj1_*	O1	distribution de classes, fréquences, proportions, diagnostics descriptifs.
stat_obj2_*	O2	scores pondérés par schéma, ρ de Spearman, overlap top-k.
Fichiers modèle O3	O3	métriques CV, prédictions, confusion et coefficients.
stat_obj4_*	O4	test choisi (χ^2 /Fisher), p -value, mesure $M = -\log_{10}(p)$.
synthèse de sélection modèle	O3	synthèse consolidée du meilleur candidat et justification numérique.

7.3.4 Couche 4 — Restitution graphique

- **Figures de pilotage** : classement sites, gradients, IR, classes patrimoniales.
- **Figures de diagnostic** : distribution fiabilité, dispersion inter-sites, sensibilité aux pondérations.
- **Formats** : PNG (consommation rapide), PDF (publication/rapport).

7.3.5 Couche 5 — Observabilité

- logs/EPFIP_CHEGD_*.log : chronologie d'exécution, anomalies, durée, statut final.

- `non_blocking_failures.csv` : journal des étapes non bloquantes en échec (si présent).
- Option recommandée : *manifest* JSON de run (version R, packages, hash input, liste outputs).

7.4 Convention de nommage

- Préfixe stable métier : `EPFIP_CHEGD`.
- Noms de fichiers en `snake_case` pour faciliter l'automatisation.
- Horodatage réservé aux logs et, si besoin, aux exports de diffusion externe.

8 Modèle de données technique

8.1 Schéma logique minimal des observations

Champ logique	Type attendu	Rôle dans le pipeline
<code>species</code>	caractère	Unité taxonomique de base pour agrégations espèce/site.
<code>family</code>	caractère	Regroupements taxonomiques et variables explicatives objectif 3.
<code>date</code>	date	Saisonnalité, agrégations temporelles et qualité de saisie.
<code>count</code>	numérique	Intensité/abondance utile aux statistiques descriptives et modèles.
<code>site</code>	caractère	Clé d'agrégation principale des indicateurs.
<code>reliability</code>	facteur ordinal	Cible ou poids selon objectifs 1 à 4.

8.2 Artefacts intermédiaires

Le pipeline manipule des tables intermédiaires standardisées :

- données nettoyées (`donnees_brutes_nettoyees`),
- agrégats site/famille/espèce/date,
- tables de scores (`potentiel`, `patrimonial`, `chegd`),
- table consolidée (`combined`) pour export et visualisation.

9 Pipeline technique détaillé

9.1 Phase A — Ingestion et normalisation

- `resolve_input_file` : résolution robuste du chemin (exact, normalisé, distance minimale),
- `read_input_data` : chargement CSV, détection séparateur CSV,
- suppression des colonnes techniques `...*`,
- conversion de types :
 - `to_date_safe` (dates Excel numériques + formats texte),
 - `to_numeric_safe` (virgule décimale).

Le pipeline intègre en outre un contrôle de qualité d'entrée exporté dans `qa_validation_entree_*.csv`, ainsi qu'un mode d'exécution `strict/tolérant` piloté par la configuration embarquée.

Les commentaires du code décrivent également la détection du séparateur CSV sur les premières lignes non vides et le nettoyage des colonnes entièrement vides, afin de fiabiliser les imports issus d'exports hétérogènes.

9.1.1 Critères de qualité de données

À l'issue de la phase A, les contrôles suivants sont attendus :

- complétude minimale des variables critiques,
- cohérence typologique (dates, numériques, facteurs),
- traçabilité des exclusions et imputations implicites.

9.2 Phase B — Calculs métier

`build_site_level_metrics` produit 4 tables :

- `potentiel`,
- `patrimonial`,
- `chegd`,
- `combined` (jointure consolidée).

9.2.1 Potentiel fongique

Score obtenu par somme pondérée de groupes/taxons indicateurs (génériques et spécifiques). Classification :

$$\text{classe} = \begin{cases} \text{faible} & \text{si } s \leq 10 \\ \text{intéressant} & \text{si } 10 < s < 30 \\ \text{élevé} & \text{si } s \geq 30 \end{cases}$$

9.2.2 Intérêt patrimonial

Soit C, H, E, G, D les effectifs des 5 groupes CHEGD.

$$I_{\text{patrimonial}} = \max(C, H, E, G, D)$$

Puis mapping vers classes ordinales (faible/local/régional/national/international).

9.2.3 Gradient CHEGD

Comptage d'espèces CHEGD par visite, puis :

$$CHEGD_{\text{total}} = \sum_v \text{gradient_visite}_v, \quad CHEGD_{\text{moyen}} = \frac{CHEGD_{\text{total}}}{N_{\text{visites}}}$$

En mode autonome, les gradients sont calculés directement à partir du CSV et des visites dérivées des dates observées. Une exception contrôlée existe pour le jeu canonique `donnees_recoltes_chegd_pelouses.csv`, où un profil de référence interne peut recalculer certains scores (potentiel/gradient) pour cohérence protocolaire.

9.2.4 Indice de représentativité (IR)

Calculé par visite selon la formule interne du script :

$$IR_{visite} = \max \left(0, 1 - \frac{gradient_visite}{nombre_total} \right)$$

avec $nombre_total = CHEGD_{total}$ au niveau site. Le pipeline exporte `ir_visite_1..5` et `ir_moyen`.

9.3 Phase C — Module fiabilité (Objectifs 1 à 4)

Le module est orchestré par `run_reliability_objectives`.

9.3.1 Contrôles préalables au module fiabilité

- Vérification du nombre minimal d'observations par classe.
- Vérification de la diversité de classes (éviter la classe unique).
- Vérification de la variance des variables explicatives principales.

9.3.2 Préparation des données fiabilité

- normalisation des niveaux : Non renseignée, Probable, Certaine,
- création de variables explicatives : abondance, saison, site, famille,
- encodage en facteur ordinal pour la cible.

9.3.3 Objectif 1 — Descriptif

Distribution fréquence/% des niveaux de fiabilité.

Sorties : `stat_obj1_reliability_distribution.csv` + figure dédiée.

9.3.4 Objectif 2 — Schémas de pondération

Trois schémas candidats (S1/S2/S3) pondèrent les niveaux de fiabilité, puis impactent un score de site.

Métriques de comparaison :

- corrélation de rang de Spearman ρ entre score de référence et score pondéré,
- overlap top-5 des sites classés.

Le meilleur schéma maximise d'abord ρ , puis l'overlap.

Sorties techniques attendues (O2)

- table des scores par site et par schéma,
- table comparative des métriques (ρ , overlap top-5),
- indicateur de robustesse de classement (fort/modéré/faible).

9.3.5 Objectif 3 — Sélection de modèles prédictifs

Cible Variable ordinale `fiabilite` à 3 niveaux.

Variables explicatives

- abundance,
- season_model,
- site_model (top-k + Autre),
- family_model (top-k + Autre).

Candidats

1. **Ordinal logit** : MASS::polr (hypothèse proportional odds),
2. **Multinomial logit** : nnet::multinom,
3. **Baseline majoritaire** : prédiction de la classe la plus fréquente.

Validation Validation croisée stratifiée à 5 folds.

Métriques

- Accuracy,
- Macro-F1,
- Log-loss multiclassées (quand probabilités disponibles).

Formules :

$$\begin{aligned} \text{Precision}_c &= \frac{TP_c}{TP_c + FP_c}, & \text{Recall}_c &= \frac{TP_c}{TP_c + FN_c} \\ F1_c &= \frac{2 \text{Precision}_c \text{Recall}_c}{\text{Precision}_c + \text{Recall}_c}, & \text{Macro-F1} &= \frac{1}{|C|} \sum_{c \in C} F1_c \\ \text{LogLoss} &= -\frac{1}{n} \sum_{i=1}^n \log p_{i,y_i} \end{aligned}$$

Le modèle retenu maximise Macro-F1 puis Accuracy.

Sorties techniques attendues (O3)

- métriques par fold et par modèle,
- moyenne/écart-type par métrique,
- matrice de confusion agrégée,
- fichier de décision finale de sélection de modèle.

Interprétation scientifique

Le choix d'une métrique prioritaire orientée classes (Macro-F1) limite l'effet de domination des classes majoritaires et soutient une interprétation plus équilibrée de la performance prédictive dans des jeux potentiellement déséquilibrés.

Cette orientation est cohérente avec les standards méthodologiques en écologie quantitative, où la performance globale doit être examinée conjointement à la performance par classe pour éviter les conclusions biaisées.

9.3.6 Objectif 4 — Inférence statistique site × fiabilité

Table de contingence `site_label` × `fiabilite`.

Stratégie de test :

- test du χ^2 si conditions d'approximation satisfaites,
- sinon test exact de Fisher,
- fallback Fisher simulé ($B = 10000$) si l'exact échoue (grandes tables).

Métrique primaire stockée :

$$M = -\log_{10}(p)$$

Plus M est grand, plus l'association est marquée.

Sorties techniques attendues (O4)

- table de contingence `site_label` × `fiabilite`,
- type de test effectivement utilisé,
- statistique de test, p -value et mesure M ,
- drapeau de fallback (exact/simulé) pour traçabilité méthodologique.

9.4 Phase D — Visualisation

Fonctions dédiées :

- `build_site_dashboard` (3 panneaux),
- `build_scatter_positionnement`,
- `build_potentiel_breakdown`,
- `build_chegd_by_visit`,
- `build_classes_heatmap`,
- `build_reliability_levels_plot`,
- `build_ir_by_visit_plot`,
- figures spécifiques objectifs 1 à 4.

9.5 Contrats graphiques

Les graphiques doivent respecter les principes suivants :

- lisibilité sur fond clair, palettes contrastées, légendes explicites,
- titres/axes homogènes en français,
- reproductibilité des dimensions d'export (PNG/PDF).

10 Mode autonome (sans dépendance classeur externe)

Le script opère en mode autonome : les fonctions de lecture/résolution d'un classeur de référence externe sont neutralisées et retournent NULL.

Conséquences techniques :

- les métriques site sont calculées directement à partir du CSV d'entrée ;
- aucun alignement automatique sur un classeur externe n'est appliqué ;
- les sorties restent entièrement déterministes pour un même input et une même configuration.

11 Exécution stricte/tolérante et étapes non bloquantes

Le paramètre `strict` de la configuration embarquée contrôle le comportement en cas d'anomalie QA :

- `strict = TRUE` : arrêt du pipeline sur contrôles bloquants.
- `strict = FALSE` : warning explicite et poursuite contrôlée.

La génération des figures et le module fiabilité sont encapsulés via `run_non_blocking_step()`. En cas d'échec local, le pipeline continue son exécution, journalise l'erreur et exporte `non_blocking_failures.csv`.

12 Logging et observabilité

12.1 Fonctions dédiées

- `setup_logging`, `log_info`, `log_warning_msg`, `log_error`,
- `log_section`, `log_header`, `log_data_summary`, `log_footer`.

12.2 Comportement

- duplication console + fichier,
- messages en français,
- étapes majeures horodatées,
- en-tête + résumé de données + pied de page (durée/chemin).

12.3 Événements clés attendus dans le log

- démarrage et chargement de configuration,
- état des données en entrée (volumétries, colonnes détectées),
- passage de chaque phase A/B/C/D,
- sorties produites (chemins de fichiers),
- erreurs bloquantes et stack simplifiée,
- durée totale d'exécution.

13 Robustesse et gestion d'erreurs

13.1 Niveaux de protection

- validation de schéma d'entrée,
- conversion défensive des types,
- `tryCatch` local sur modèles/tests sensibles,
- `tryCatch` global autour de `main()`.

13.2 Fallbacks notables

- fallback Fisher simulé en inférence,
- baseline majoritaire si modèles indisponibles,
- gestion classe unique / données insuffisantes pour l'objectif 3.

13.3 Politique de sévérité des anomalies

Niveau	Exemple	Action système
INFO	Volumétrie et progression	Trace sans interruption
ALERTE	Valeurs partiellement manquantes/non standard	Poursuite avec normalisation ou exclusion ciblée
ERREUR	Colonnes obligatoires absentes, lecture impossible	Arrêt propre avec message explicite

14 Contrôles qualité et non-régression

14.1 Indicateurs d'assurance qualité (QA) exportés

Dans `resume_global.csv` :

- `coherence_chegd_gradients_ok`,
- `nb_sites_incoherents_chegd`,
- `ir_moyen_global`,
- métriques volumétriques (nb lignes, espèces, familles, sites, dates).

14.2 Critères techniques d'acceptation

1. exécution sans erreur fatale,
2. génération complète des sorties CSV/figures,
3. log horodaté présent dans `logs/`,
4. cohérence gradients CHEGD validée.

14.3 Stratégie de tests recommandée

- **Tests unitaires** : fonctions de conversion et formules métier (potentiel, CHEGD, IR).
- **Tests d'intégration** : exécution de bout en bout sur un jeu réduit connu.
- **Tests de non-régression** : comparaison d'exports clés avec des snapshots de référence.
- **Tests de robustesse** : jeux volontairement bruités (dates ambiguës, valeurs manquantes, classes rares).

14.4 Matrice de validation des artefacts

Bloc	Règle de validation	Preuve attendue
Ingestion	Colonnes critiques présentes et typées	<code>donnees_brutes_nettoyees.csv</code> + warnings ciblés dans log
Indicateurs métier	1 ligne par site, pas de duplication clé	<code>tables *_par_site.csv</code> cohérentes
CHEGD/IR	somme gradients visite cohérente avec total	QA indicateur de cohérence CHEGD
Objectif 2	classement stable sous pondérations	<code>stat_obj2_*.csv</code> avec ρ et overlap
Objectif 3	modèle gagnant justifié numériquement	synthèse de sélection modèle
Objectif 4	type de test tracé et interprétable	<code>stat_obj4_*.csv</code> + log test
Observabilité	run horodaté complet	fichier <code>logs/EPFIP_CHEGD_*.log</code>

14.5 Critères de stabilité statistique recommandés

Pour une exploitation en contexte institutionnel, il est recommandé de viser :

- une variabilité inter-fold modérée des métriques O3 (écart-type limité),
- une corrélation de rang O2 élevée (idéalement $\rho \geq 0.85$),
- une cohérence des conclusions O4 entre test principal et fallback simulé,
- une documentation explicite de toute déviation méthodologique dans le log.

14.6 Menaces à la validité

- **Validité interne** : dépend de la qualité des transformations de variables et de la stabilité des mappings.
- **Validité externe** : transférabilité limitée si nouveaux territoires ou protocoles d'échantillonnage très différents.
- **Validité de conclusion** : prudence requise en cas d'effectifs faibles par classe pour l'inférence site $\times$ fiabilité.

15 Complexité et performances (qualitatives)

- Agrégations principales : complexité proche de $O(n)$ à $O(n \log n)$ selon tris/groupements,
- Objectif 3 : coût dominant, approximativement proportionnel à $k \times m$ (folds $\times$ modèles) multiplié par le coût d'entraînement,
- Visualisations : coût linéaire en nombre de points/agrégats.

15.1 Pistes d’optimisation

- limiter les copies de tables intermédiaires volumineuses,
- mutualiser les agrégations redondantes,
- mémoriser certains objets dérivés (facteurs top-k) entre objectifs,
- paralléliser la validation croisée si nécessaire (selon environnement d’exécution).

16 Sécurité, conformité et exploitation

16.1 Sécurité des données

- pas de secret applicatif requis pour l’exécution standard,
- privilégier des chemins locaux contrôlés pour les données sources,
- limiter la diffusion des logs si ceux-ci contiennent des métadonnées sensibles.

16.2 Conformité et bonnes pratiques

- conserver la provenance des données (source, date d’extraction),
- documenter les transformations non triviales,
- archiver le triplet *input + outputs + log* pour auditabilité.

16.3 Procédure opératoire standard (POS)

1. Vérifier présence du fichier d’entrée et structure minimale des colonnes.
2. Exécuter le script dans l’environnement R cible.
3. Contrôler le log et les indicateurs QA de `resume_global.csv`.
4. Diffuser les exports validés vers l’équipe métier.
5. Archiver les artefacts de run avec identifiant de campagne.

17 Réplicabilité et transparence scientifique

Afin de favoriser la réplification des résultats, chaque exécution devrait documenter :

- la version de R et des packages,
- le hachage ou l’empreinte du jeu d’entrée,
- les paramètres de configuration effectifs,
- les sorties consolidées (CSV, figures, log) associées au même identifiant de run.

17.1 Spécification d'un manifeste de run (recommandée)

Format proposé : `run_manifest.json` stocké à la racine des résultats. Champs minimaux suggérés :

- `run_id`, `timestamp_start`, `timestamp_end`,
- `r_version`, `packages` (versions),
- `input_file`, `input_hash`,
- `config_effective`,
- `outputs_generated` (liste exhaustive),
- `qa_summary` (cohérence CHEGD, nombre d'alertes, statut final).

Ce manifeste facilite les audits comparatifs inter-campagnes et la reproductibilité scientifique au-delà du seul environnement local d'exécution.

18 Évolutions techniques recommandées

- externaliser les seuils et poids métier dans un bloc paramétrable,
- factoriser les fonctions communes entre script principal et alias historique,
- ajouter une suite de tests unitaires ciblant les formules métier,
- versionner les modèles/statistiques de fiabilité avec métadonnées de run.

19 Protocole de base

Ce pipeline implémente le protocole d'évaluation décrit par Yann Sellier & co :

Sellier, Y. et coll. (s.d.). Évaluation du potentiel fongique et de l'intérêt patrimonial des pelouses. Ressource en ligne : <https://www.mycofrance.fr/wp-content/uploads/2025/05/Bull.-SMF-131-1-2-Y-Sellier-et-coll.pdf>.

Le protocole original spécifie :

- Les cinq groupes CHEGD : Clavaria, Hygrocybe, Entoloma, Geoglossaceae, Dermoloma.
- Les pondérations de potentiel fongique par espèce/groupe indicateur.
- L'indice patrimonial comme maximum des effectifs CHEGD.
- L'indice de représentativité relatif au gradient CHEGD par visite.

20 Références bibliographiques (style harmonisé)

- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The elements of statistical learning* (2nd ed.). Springer.
- ISO. (s.d.). *ISO 8000 series – Data quality*. International Organization for Standardization.
- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An introduction to statistical learning* (2nd ed.). Springer.

- Sellier, Y., et coll. (s.d.). *Évaluation du potentiel fongique et de l'intérêt patrimonial des pelouses*. Mycofrance. <https://www.mycofrance.fr/wp-content/uploads/2025/05/Bull.-SMF-131-1-2-Y-Sellier-et-coll.pdf>.
- Wickham, H., & Grolemund, G. (2017). *R for data science*. O'Reilly.

Contact et versionnement

Auteur	Eddy Boite
Dépôt GitHub	eddyboite-nat/myco_apps_releases
Branche	main
Version script	1.1
Date de ce document	9 juillet 2026

Pour toute évolution du script, ouvrir une issue dans le dépôt GitHub ou documenter les changements dans le journal `CHANGELOG.md` du projet.