

Conception Technique

Evaluation_Potentiel_Fongique_Interets_Patrimoniaux_CHEGD

Boite Eddy

15 juin 2026

Résumé

Ce document présente la conception technique d'un pipeline d'analyse mycologique destiné à l'évaluation du potentiel fongique, de l'intérêt patrimonial et de la fiabilité de détermination. La description adopte un cadre d'ingénierie reproductible : architecture, contrats de données, méthodes statistiques, robustesse opérationnelle et critères de qualité. L'ambition est de fournir un protocole techniquement auditable, scientifiquement explicitable et réutilisable pour des campagnes futures.

Table des matières

1	Positionnement méthodologique	3
2	Objectif technique	3
3	Architecture logicielle	3
3.1	Style d'architecture	3
3.2	Principes de conception	3
3.3	Points d'entrée	3
3.4	Configuration	4
3.5	Surcharge de configuration	4
4	Dépendances techniques	4
4.1	Packages R	4
4.2	Comportement d'installation	4
5	Contrats d'entrée et de sortie	4
5.1	Entrées	4
5.2	Sorties	4
5.3	Convention de nommage	5
6	Modèle de données technique	5
6.1	Schéma logique minimal des observations	5
6.2	Artefacts intermédiaires	5
7	Pipeline technique détaillé	5
7.1	Phase A — Ingestion et normalisation	5
7.1.1	Critères de qualité de données	6
7.2	Phase B — Calculs métier	6
7.2.1	Potentiel fongique	6
7.2.2	Intérêt patrimonial	6
7.2.3	Gradient CHEGD	6
7.2.4	Indice de représentativité (IR)	6

7.3	Phase C — Module fiabilité (Objectifs 1 à 4)	7
7.3.1	Contrôles préalables au module fiabilité	7
7.3.2	Préparation des données fiabilité	7
7.3.3	Objectif 1 — Descriptif	7
7.3.4	Objectif 2 — Schémas de pondération	7
7.3.5	Objectif 3 — Sélection de modèles prédictifs	7
7.3.6	Objectif 4 — Inférence statistique site $\times$ fiabilité	8
7.4	Phase D — Visualisation	8
7.5	Contrats graphiques	9
8	Alignement référence (mode fidélité Excel)	9
8.1	Détection	9
8.2	Feuilles exploitées	9
8.3	Principe technique	9
9	Logging et observabilité	9
9.1	Fonctions dédiées	9
9.2	Comportement	9
9.3	Événements clés attendus dans le log	10
10	Robustesse et gestion d’erreurs	10
10.1	Niveaux de protection	10
10.2	Fallbacks notables	10
10.3	Politique de sévérité des anomalies	10
11	Contrôles qualité et non-régression	10
11.1	Indicateurs QA exportés	10
11.2	Critères techniques d’acceptation	11
11.3	Stratégie de tests recommandée	11
11.4	Menaces à la validité	11
12	Complexité et performances (qualitatives)	11
12.1	Pistes d’optimisation	11
13	Sécurité, conformité et exploitation	11
13.1	Sécurité des données	11
13.2	Conformité et bonnes pratiques	12
13.3	Runbook d’exploitation (opérationnel)	12
14	Répliquabilité et transparence scientifique	12
15	Évolutions techniques recommandées	12
16	Références bibliographiques indicatives	12

1 Positionnement méthodologique

Le pipeline relève d'une approche *data-centric* appliquée à l'écologie, où les indicateurs métiers sont construits à partir de transformations successives, puis consolidés par des procédures d'inférence statistique. Deux objectifs sont poursuivis simultanément :

- **validité analytique** (qualité des estimations et des tests),
- **validité opérationnelle** (stabilité des sorties, exploitabilité décisionnelle).

2 Objectif technique

Ce document décrit l'architecture technique du script [scripts/Evaluation_Potentiel_Fongique_Interets_Patrimoniaux_CHEGD.R](#), avec un focus sur :

- la chaîne de traitement de données,
- la logique de calcul des indicateurs métier,
- les modèles statistiques utilisés,
- la robustesse (contrôles, fallback, logging, QA).

3 Architecture logicielle

3.1 Style d'architecture

Le script suit une architecture **pipeline batch séquentielle**, organisée en modules fonctionnels :

1. Initialisation (packages, config embarquée, logging),
2. Ingestion/normalisation des données,
3. Calculs métier par site,
4. Module de fiabilité (objectifs statistiques 1 à 4),
5. Génération des exports et visualisations,
6. Finalisation et journalisation.

3.2 Principes de conception

- **Déterminisme** : mêmes entrées + même configuration $\Rightarrow$ mêmes sorties (hors horodatage).
- **Tolérance aux variations de données** : conversions défensives et diagnostics explicites.
- **Traçabilité by design** : chaque phase significative est loguée.
- **Séparation logique** : ingestion, calcul métier, fiabilité, restitution.

3.3 Points d'entrée

- `main()` : orchestration principale.
- Bloc `tryCatch` final : capture d'erreurs globales + log d'échec.

3.4 Configuration

La configuration est intégrée via `get_embedded_config()` :

```
input_file      = data/donnees_recoltes_chegd_pelouses.csv
input_sheet     = NULL
output_dir      = results
output_prefix   = EPFIP_CHEGD
columns         = {species, family, date, count, site, reliability}
```

3.5 Surcharge de configuration

Bien que la configuration soit embarquée, le design prévoit une extension simple vers une surcharge par fichier externe (ex. YAML/JSON) pour :

- les seuils métiers,
- les mappings de colonnes,
- les chemins d'entrée/sortie,
- les paramètres de visualisation.

4 Dépendances techniques

4.1 Packages R

- `readxl` : lecture Excel,
- `dplyr`, `stringr` : transformation/normalisation,
- `ggplot2`, `gridExtra` : visualisation,
- `MASS` : régression ordinale `polr`,
- `nnet` : régression multinomiale `multinom`.

4.2 Comportement d'installation

Les packages manquants sont installés au démarrage : `requireNamespace(...)` vérifie leur présence, puis `install.packages(...)` les installe si nécessaire.

5 Contrats d'entrée et de sortie

5.1 Entrées

Formats supportés : `.csv`, `.xlsx`. Colonnes obligatoires : espèce, famille, date, effectif, site, fiabilité.

5.2 Sorties

- Répertoire fixe : `results/EPFIP_CHEGD/`
- Logs : `logs/EPFIP_CHEGD_YYYYMMDD_HHMM.log`
- CSV de synthèse : résumés, indicateurs, QA, objectifs fiabilité
- Figures PNG/PDF : `fig1` à `fig7` + figures objectives.

5.3 Convention de nommage

- Préfixe stable métier : EPFIP_CHEGD.
- Noms de fichiers en **snake_case** pour faciliter l'automatisation.
- Horodatage réservé aux logs et, si besoin, aux exports de diffusion externe.

6 Modèle de données technique

6.1 Schéma logique minimal des observations

Champ logique	Type attendu	Rôle dans le pipeline
species	caractère	Unité taxonomique de base pour agrégations espèce/site.
family	caractère	Regroupements taxonomiques et variables explicatives objectif 3.
date	date	Saisonnalité, agrégations temporelles et qualité de saisie.
count	numérique	Intensité/abondance utile aux statistiques descriptives et modèles.
site	caractère	Clé d'agrégation principale des indicateurs.
reliability	facteur ordinal	Cible ou poids selon objectifs 1 à 4.

6.2 Artefacts intermédiaires

Le pipeline manipule des tables intermédiaires standardisées :

- données nettoyées (`donnees_brutes_nettoyees`),
- agrégats site/famille/espèce/date,
- tables de scores (`potentiel`, `patrimonial`, `chegd`),
- table consolidée (`combined`) pour export et visualisation.

7 Pipeline technique détaillé

7.1 Phase A — Ingestion et normalisation

- `resolve_input_file` : résolution robuste du chemin (exact, normalisé, distance minimale),
- `read_input_data` : chargement CSV/XLSX, détection séparateur CSV,
- suppression des colonnes techniques `...*`,
- conversion de types :
 - `to_date_safe` (dates Excel numériques + formats texte),
 - `to_numeric_safe` (virgule décimale).

7.1.1 Critères de qualité de données

À l'issue de la phase A, les contrôles suivants sont attendus :

- complétude minimale des variables critiques,
- cohérence typologique (dates, numériques, facteurs),
- traçabilité des exclusions et imputations implicites.

7.2 Phase B — Calculs métier

`build_site_level_metrics` produit 4 tables :

- `potentiel`,
- `patrimonial`,
- `chedg`,
- `combined` (jointure consolidée).

7.2.1 Potentiel fongique

Score obtenu par somme pondérée de groupes/taxons indicateurs (génériques et spécifiques). Classification :

$$\text{classe} = \begin{cases} \text{faible} & \text{si } s \leq 10 \\ \text{intéressant} & \text{si } 10 < s < 30 \\ \text{élevé} & \text{si } s \geq 30 \end{cases}$$

7.2.2 Intérêt patrimonial

Soit C, H, E, G, D les effectifs des 5 groupes CHEGD.

$$I_{\text{patrimonial}} = \max(C, H, E, G, D)$$

Puis mapping vers classes ordinales (faible/local/régional/national/international).

7.2.3 Gradient CHEGD

Comptage d'espèces CHEGD par visite, puis :

$$CHEGD_{\text{total}} = \sum_v \text{gradient_visite}_v, \quad CHEGD_{\text{moyen}} = \frac{CHEGD_{\text{total}}}{N_{\text{visites}}}$$

En mode référence, les valeurs peuvent être alignées depuis le classeur externe, avec réajustement des gradients par visite pour conserver la cohérence des sommes.

7.2.4 Indice de représentativité (IR)

Calculé par visite selon le modèle Excel :

$$IR_{\text{visite}} = \max\left(0, 1 - \frac{\text{gradient_visite}}{\text{nombre_total}}\right)$$

avec $\text{nombre_total} = CHEGD_{\text{total}}$ au niveau site. Le pipeline exporte `ir_visite_1..5` et `ir_moyen`.

7.3 Phase C — Module fiabilité (Objectifs 1 à 4)

Le module est orchestré par `run_reliability_objectives`.

7.3.1 Contrôles préalables au module fiabilité

- Vérification du nombre minimal d'observations par classe.
- Vérification de la diversité de classes (éviter la classe unique).
- Vérification de la variance des variables explicatives principales.

7.3.2 Préparation des données fiabilité

- normalisation des niveaux : Non renseignée, Probable, Certaine,
- création de variables explicatives : abondance, saison, site, famille,
- encodage en facteur ordinal pour la cible.

7.3.3 Objectif 1 — Descriptif

Distribution fréquence/% des niveaux de fiabilité.

Sorties : `stat_obj1_reliability_distribution.csv` + figure dédiée.

7.3.4 Objectif 2 — Schémas de pondération

Trois schémas candidats (S1/S2/S3) pondèrent les niveaux de fiabilité, puis impactent un score de site.

Métriques de comparaison :

- corrélation de rang de Spearman ρ entre score de référence et score pondéré,
- overlap top-5 des sites classés.

Le meilleur schéma maximise d'abord ρ , puis l'overlap.

7.3.5 Objectif 3 — Sélection de modèles prédictifs

Cible Variable ordinale `fiabilite` à 3 niveaux.

Features

- `abundance`,
- `season_model`,
- `site_model` (top-k + Autre),
- `family_model` (top-k + Autre).

Candidats

1. **Ordinal logit** : `MASS::polr` (hypothèse proportional odds),
2. **Multinomial logit** : `nnet::multinom`,
3. **Baseline majoritaire** : prédiction de la classe la plus fréquente.

Validation Validation croisée stratifiée à 5 folds.

Métriques

- Accuracy,
- Macro-F1,
- Log-loss multiclassées (quand probabilités disponibles).

Formules :

$$\text{Precision}_c = \frac{TP_c}{TP_c + FP_c}, \quad \text{Recall}_c = \frac{TP_c}{TP_c + FN_c}$$
$$F1_c = \frac{2 \text{Precision}_c \text{Recall}_c}{\text{Precision}_c + \text{Recall}_c}, \quad \text{Macro-F1} = \frac{1}{|C|} \sum_{c \in C} F1_c$$

$$\text{LogLoss} = -\frac{1}{n} \sum_{i=1}^n \log p_{i,y_i}$$

Le modèle retenu maximise Macro-F1 puis Accuracy.

Interprétation scientifique Le choix d'une métrique prioritaire orientée classes (Macro-F1) limite l'effet de domination des classes majoritaires et soutient une interprétation plus équilibrée de la performance prédictive dans des jeux potentiellement déséquilibrés.

7.3.6 Objectif 4 — Inférence statistique site × fiabilité

Table de contingence `site_label` × `fiabilite`.

Stratégie de test :

- test du χ^2 si conditions d'approximation satisfaites,
- sinon test exact de Fisher,
- fallback Fisher simulé ($B = 10000$) si l'exact échoue (grandes tables).

Métrique primaire stockée :

$$M = -\log_{10}(p)$$

Plus M est grand, plus l'association est marquée.

7.4 Phase D — Visualisation

Fonctions dédiées :

- `build_site_dashboard` (3 panneaux),
- `build_scatter_positionnement`,
- `build_potentiel_breakdown`,
- `build_chegd_by_visit`,
- `build_classes_heatmap`,
- `build_reliability_levels_plot`,
- `build_ir_by_visit_plot`,
- figures spécifiques objectifs 1 à 4.

7.5 Contrats graphiques

Les graphiques doivent respecter les principes suivants :

- lisibilité sur fond clair, palettes contrastées, légendes explicites,
- titres/axes homogènes en français,
- reproductibilité des dimensions d'export (PNG/PDF).

8 Alignement référence (mode fidélité Excel)

8.1 Détection

Recherche d'un classeur `.xlsx` (hors input) contenant la feuille `Visites sur sites`.

8.2 Feuilles exploitées

- Analyse des résultats,
- Intérêt patrimonial,
- `Visites sur sites`,
- Évaluation CHEGD pelouses.

8.3 Principe technique

Les métriques calculées localement peuvent être remplacées par les références, puis consolidées dans `combined`. Les gradients par visite sont prioritairement alignés sur `Évaluation CHEGD pelouses`, ce qui garantit la reproduction exacte de l'IR du classeur. Objectif : reproductibilité métier avec le classeur de référence.

9 Logging et observabilité

9.1 Fonctions dédiées

- `setup_logging`, `log_info`, `log_warning_msg`, `log_error`,
- `log_section`, `log_header`, `log_data_summary`, `log_footer`.

9.2 Comportement

- duplication console + fichier,
- messages en français,
- étapes majeures horodatées,
- en-tête + résumé de données + pied de page (durée/chemin).

9.3 Événements clés attendus dans le log

- démarrage et chargement de configuration,
- état des données en entrée (volumétries, colonnes détectées),
- passage de chaque phase A/B/C/D,
- sorties produites (chemins de fichiers),
- erreurs bloquantes et stack simplifiée,
- durée totale d'exécution.

10 Robustesse et gestion d'erreurs

10.1 Niveaux de protection

- validation de schéma d'entrée,
- conversion défensive des types,
- `tryCatch` local sur modèles/tests sensibles,
- `tryCatch` global autour de `main()`.

10.2 Fallbacks notables

- fallback Fisher simulé en inférence,
- baseline majoritaire si modèles indisponibles,
- gestion classe unique / données insuffisantes pour l'objectif 3.

10.3 Politique de sévérité des anomalies

Niveau	Exemple	Action système
INFO	Volumétrie et progression	Trace sans interruption
WARNING	Valeurs partiellement manquantes/non standard	Poursuite avec normalisation ou exclusion ciblée
ERROR	Colonnes obligatoires absentes, lecture impossible	Arrêt propre avec message explicite

11 Contrôles qualité et non-régression

11.1 Indicateurs QA exportés

Dans `resume_global.csv` :

- `coherence_chegd_gradients_ok`,
- `nb_sites_incoherents_chegd`,
- `ir_moyen_global`,
- métriques volumétriques (nb lignes, espèces, familles, sites, dates).

11.2 Critères techniques d'acceptation

1. exécution sans erreur fatale,
2. génération complète des sorties CSV/figures,
3. log horodaté présent dans logs/,
4. cohérence gradients CHEGD validée.

11.3 Stratégie de tests recommandée

- **Tests unitaires** : fonctions de conversion et formules métier (potentiel, CHEGD, IR).
- **Tests d'intégration** : exécution de bout en bout sur un jeu réduit connu.
- **Tests de non-régression** : comparaison d'exports clés avec des snapshots de référence.
- **Tests de robustesse** : jeux volontairement bruités (dates ambiguës, valeurs manquantes, classes rares).

11.4 Menaces à la validité

- **Validité interne** : dépend de la qualité des transformations de variables et de la stabilité des mappings.
- **Validité externe** : transférabilité limitée si nouveaux territoires ou protocoles d'échantillonnage très différents.
- **Validité de conclusion** : prudence requise en cas d'effectifs faibles par classe pour l'inférence site $\times$ fiabilité.

12 Complexité et performances (qualitatives)

- Agrégations principales : complexité proche de $O(n)$ à $O(n \log n)$ selon tris/groupements,
- Objectif 3 : coût dominant, approximativement proportionnel à $k \times m$ (folds $\times$ modèles) multiplié par le coût d'entraînement,
- Visualisations : coût linéaire en nombre de points/agrégats.

12.1 Pistes d'optimisation

- limiter les copies de tables intermédiaires volumineuses,
- mutualiser les agrégations redondantes,
- mémoriser certains objets dérivés (facteurs top-k) entre objectifs,
- paralléliser la validation croisée si nécessaire (selon environnement d'exécution).

13 Sécurité, conformité et exploitation

13.1 Sécurité des données

- pas de secret applicatif requis pour l'exécution standard,
- privilégier des chemins locaux contrôlés pour les données sources,
- limiter la diffusion des logs si ceux-ci contiennent des métadonnées sensibles.

13.2 Conformité et bonnes pratiques

- conserver la provenance des données (source, date d'extraction),
- documenter les transformations non triviales,
- archiver le triplet *input + outputs + log* pour auditabilité.

13.3 Runbook d'exploitation (opérationnel)

1. Vérifier présence du fichier d'entrée et structure minimale des colonnes.
2. Exécuter le script dans l'environnement R cible.
3. Contrôler le log et les indicateurs QA de `resume_global.csv`.
4. Diffuser les exports validés vers l'équipe métier.
5. Archiver les artefacts de run avec identifiant de campagne.

14 Réplicabilité et transparence scientifique

Afin de favoriser la réplification des résultats, chaque exécution devrait documenter :

- la version de R et des packages,
- le hachage ou l'empreinte du jeu d'entrée,
- les paramètres de configuration effectifs,
- les sorties consolidées (CSV, figures, log) associées au même identifiant de run.

Une extension recommandée consiste à publier un *manifest* technique automatique (fichier texte ou JSON) pour chaque run, facilitant audit, réplification et comparaison inter-campagnes.

15 Évolutions techniques recommandées

- externaliser les seuils et poids métier dans un bloc paramétrable,
- factoriser les fonctions communes entre script principal et alias historique,
- ajouter une suite de tests unitaires ciblant les formules métier,
- versionner les modèles/statistiques de fiabilité avec métadonnées de run.

16 Références bibliographiques indicatives

- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning*. Springer.
- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning*. Springer.
- Wickham, H. & Grolemund, G. (2017). *R for Data Science*. O'Reilly.
- ISO 8000 (série). *Data quality*.