

Inventaires fongiques – Spécification fonctionnelle (ICR)

Eddy Boite

9 juillet 2026 – v1.4

Objectif

Ce document formalise les exigences fonctionnelles du script `scripts/Inventaires_completude_represent` (v1.4) pour l’analyse de complétude et de représentativité d’inventaires fongiques.

Fonctions livrées :

1. courbe temps-espèces,
2. ajustements linéaire/hyperbolique (si conditions remplies),
3. estimation d’asymptote,
4. calcul de TEE et de $Ir = 1 - TEE$,
5. fréquences d’occurrence par espèce,
6. occupation spatiale (si `placette`),
7. CA/AFC (si `vegan`),
8. métriques de pertinence scientifique,
9. manifeste final de production.

Entrées

Fichier principal

`data/observations.csv` (ou `.txt/.tsv`)

Colonnes

- Obligatoires : `site`, `date`, `visite_id`, `espece`
- Optionnelle : `placette`

Règles fonctionnelles

- Parsing date via `INVENTAIRES_DATE_FORMAT` (défaut : `%Y-%m-%d`).
- Déduplication sur (`site`, `placette`, `date`, `visite_id`, `espece`).
- Visite distincte : `date + visite_id` (et `site` en multi-sites).

Configuration centralisée

Tous les paramètres du pipeline sont définis dans la fonction `get_embedded_config()` et affichés dans l’en-tête du script au démarrage. La configuration supporte les surcharges via variables d’environnement `INVENTAIRES_*` :

- `INVENTAIRES_INPUT_FILE` : chemin du fichier source
- `INVENTAIRES_OUTPUT_DIR` : répertoire de sortie

- INVENTAIRES_DATE_FORMAT : format des dates
- INVENTAIRES_CSV_STRICT : mode strict (booléen)
- INVENTAIRES_CSV_ALLOW_EXTRA_COLS : tolérance colonnes supplémentaires
- INVENTAIRES_FREQ_BREAKS : séquence des intervalles de fréquence
- INVENTAIRES_FREQ_LABELS : étiquettes des intervalles
- INVENTAIRES_MAKE_CA : activer CA/AFC (booléen)
- INVENTAIRES_MIN_VISITS_FOR_MODEL : seuil de modélisation
- INVENTAIRES_WIDTH, INVENTAIRES_HEIGHT, INVENTAIRES_DPI : paramètres graphiques

Aucune modification du code source n'est nécessaire : les paramètres peuvent être ajustés par variable d'environnement.

Validation CSV

Le contrôle de conformité est exécuté avant traitement.

- results/ICR/ICR_00_csv_conformite_report.csv (toujours)
- results/ICR/ICR_00_csv_conformite_problems.csv (si anomalies)

En mode strict (INVENTAIRES_CSV_STRICT=TRUE), la non-conformité est bloquante.

Sorties attendues

Organisation thématique

Les résultats sont organisés selon une hiérarchie thématique sous **results/ICR/** :

- 00_data_quality/ : rapports d'audit CSV et conformité
- 01_richesse/, 02_completude_repr/, 03_frequencies/ : analyses par site (réservées)
- 04_spatial/, 05_temporal/ : analyses spéciales (réservées)
- 06_metrics/ : métriques scientifiques globales
- comparisons/ : visualisations comparatives multi-sites
- sites/<site_name>/ : **TOUS les fichiers par site** (organisés en un seul répertoire)

Globales (results/ICR/)

- ICR_donnees_preparees.csv
- ICR_resume_tous_sites.csv
- ICR_metrics_pertinence_tous_sites.csv
- ICR_comparaison_completude_sites.png (dans comparisons/)
- ICR_comparaison_ir_sites.png (dans comparisons/)
- ICR_metrics_pertinence_heatmap_sites.png (dans comparisons/)
- ICR_metrics_pertinence_score_sites.png (dans comparisons/)

Par site (results/ICR/sites/<site_name>/)

Tous les fichiers CSV et PNG d'un site sont consolidés dans un seul répertoire :

- ICR_01_courbe_temps_especes.csv et graphique PNG
- ICR_02_tee_ir.csv et graphique PNG
- ICR_03_freguence_especes.csv et graphique PNG
- ICR_04_resume_site.csv
- ICR_07_metrics_pertinence.csv et graphique PNG
- ICR_05_modeles.csv (si conditions remplies)
- ICR_06_occupation_spatiale.csv (si placette)
- ICR_05_temporel_vs_spatial.png (conditionnelle)
- ICR_06_CA_placettes_especes.png (si vegan et placette)

Indicateurs

TEE

Proportion d'espèces observées une seule fois.

Indice de représentativité

$$Ir = 1 - TEE$$

Repères : $Ir < 0.60$ (faible), $0.60 \leq Ir < 0.80$ (moyenne), $Ir \geq 0.80$ (bonne).

Complétude

$$\text{Complétude} = \frac{S_{obs}}{S_{asymptote}}$$

Repères : < 0.70 (insuffisante), $0.70-0.90$ (intermédiaire), ≥ 0.90 (avancée).

Logging systématisé

Chaque exécution du script génère un fichier log horodaté dans le répertoire `logs/` du projet :

- **Format du nom** : `ICR_YYYYMMDD_HHMM.log`
- **Format des entées** : `[YYYY-MM-DD HH:MM:SS] [LEVEL] message`
- **Niveaux** : `INFO`, `DEBUG`, `WARN`

Les logs enregistrent :

1. En-tête du script (nom, version, timestamp, répertoire de travail, version R)
2. Chaque étape du pipeline (résolution fichier, audit CSV, analyses par site)
3. Les paramètres de configuration actifs au démarrage
4. Le manifeste final des livrables avec statuts (`OK`, `MANQUANT`, `OPTIONNEL_NON_GENERE`)

Les avertissements sont également affichés en console et dans les logs en niveau `WARN`.

Variables d'environnement supportées

- `INVENTAIRES_INPUT_FILE`
- `INVENTAIRES_OUTPUT_DIR`
- `INVENTAIRES_DATE_FORMAT`
- `INVENTAIRES_CSV_STRICT`
- `INVENTAIRES_CSV_ALLOW_EXTRA_COLS`
- `INVENTAIRES_AUTO_RUN`

Modes d'exécution

Le script peut être exécuté en mode standard (recommandé) ou avec des flags internes :

- `DEBUG_MODE = TRUE` : verbosité accrue et affichage détaillé des avertissements.
- `BENCHMARK_MODE = TRUE` : mesure des temps sur les calculs principaux.
- `CLEAN_ENVIRONMENT = TRUE` : nettoyage de l'environnement avant exécution (usage expert).

Le comportement d'auto-lancement est piloté par `INVENTAIRES_AUTO_RUN` (défaut : `TRUE`).

Améliorations du script (v1.4)

Phase 1 : Fiabilisation

Gestion robuste des formats de fichiers hétérogènes, déduplication intelligente des observations, traitement des dates flexibles, gestion des erreurs CSV granulaire.

Phase 2 : Performance

Optimisation du modèle hyperbolique via `minpack.lm::nlsLM`, calculs vectorisés par site, graphiques pré-calculés en mémoire avant export PNG.

Phase 3 : Graphiques et visualisations

Cartes de chaleur multi-sites, tableaux de bord par site (7 graphiques), comparaisons visuelles de complétude, analyses de CA/AFC si `vegan` disponible.

Phase 4 : Industrialisation

1. **Configuration centralisée** : fonction `get_embedded_config()` avec 14+ paramètres, surchargeable via variables d'environnement
2. **Logging systématisé** : fichiers logs horodatés avec métadonnées d'exécution, manifeste final des livrables
3. **Organisation thématique** : hiérarchie logique `/sites/`, `/comparisons/`, répertoires réservés pour extensions futures
4. **Métriques scientifiques** : pertinence des espèces, scores de complétude détaillés, dashboards analytiques

Journalisation fonctionnelle

La sortie est journalisée en console (niveaux info/debug/warning), puis un manifeste final indique l'état des livrables : OK, MANQUANT, OPTIONNEL_NON_GENERE.

Le script applique enfin une politique stricte de nettoyage du fichier parasite `Rplots.pdf` lorsqu'il est généré pendant l'exécution.

Dépendances

Requises : `dplyr`, `tidyr`, `ggplot2`, `purrr`, `readr`, `stringr`, `forcats`, `tibble`, `scales`, `gridExtra`.
Optionnelles : `minpack.lm` (modèle hyperbolique), `vegan` (CA/AFC).

=====

Auteur	Eddy Boite
Dépôt GitHub	eddyboite-nat/myco_apps_releases
Branche	main
Version script	1.1
Date de ce document	9 juillet 2026

Pour toute évolution du script, ouvrir une issue dans le dépôt GitHub ou documenter les changements dans le journal `CHANGELOG.md` du projet.