

Inventaires fongiques – Spécification technique (ICR)

Eddy Boite

9 juillet 2026 – v1.4

Vue d'ensemble

Ce document décrit l'architecture technique du script `scripts/Inventaires_completude_representativite.R` (v1.4). Il précise les contrats d'entrée/sortie, la configuration runtime et les limites opérationnelles.

Architecture logique

Blocs principaux

1. Initialisation et validation de configuration
2. Résolution du fichier d'entrée
3. Lecture auto-délimiteur
4. Audit CSV et export de conformité
5. Préparation/nettoyage des données
6. Analyse par site
7. Consolidation multi-sites
8. Export des livrables CSV/PNG
9. Manifeste de sortie

Fonctions clés

- **Configuration et logging** : `get_embedded_config()`, `setup_logging()`, `log_message()`, `log_info()`, `log_debug()`, `log_warning()`, `log_header()`, `log_section()`
- **Résolution et validation** : `resolve_path()`, `resolve_input_file()`, `validate_config()`, `check_required_packages()`
- **Lecture et audit** : `read_delim_auto()`, `audit_csv_conformity()`, `export_csv_conformity_report()`
- **Préparation** : `prepare_data()`, `deduplicate_observations()`
- **Analyses univariées** : `calc_cumulative_metrics()`, `calc_tee_ir()`, `calc_species_frequency()`, `calc_spatial_occupancy()`
- **Modélisation** : `fit_linear_model()`, `fit_hyperbolic_model()`, `fit_assymptote()`
- **Métriques avancées** : `calc_scientific_metrics()`, `calc_ca_analysis()`
- **Orchestration** : `analyze_site()`, `run_analysis()`, `log_output_manifest()`, `ensure_thematic_dirs()`

Configuration runtime (CONFIG)

Clé	Défaut	Description
input_file	data/ observations. csv	Fichier source
output_dir	results/ICR	Répertoire de sortie
date_format	%Y-%m-%d	Parsing des dates
csv_strict_mode	TRUE	Arrêt si CSV non conforme
csv_allow_extra_cols	FALSE	Tolérance des colonnes supplémentaires
csv_required_cols	site,date, visite_id, espece	Schéma obligatoire
csv_optional_cols	placette	Schéma optionnel
freq_breaks	0, 1, 2, 5, 10, Inf	Séquence des intervalles de fréquence
freq_labels	1, 2, 3-5, 6-10, 10+	Étiquettes des intervalles
make_ca	TRUE	Active la CA/AFC si possible
min_visits_for_model	5	Seuil de modélisation
width	10	Largeur graphiques PNG (pouces)
height	6	Hauteur graphiques PNG (pouces)
dpi	300	Résolution graphiques PNG (points/pouce)

Toutes ces clés supportent les surcharges via variables d'environnement `INVENTAIRES_*`. La configuration est affichée dans l'en-tête du script via la fonction `print_startup_header()`.

Variables d'environnement principales : `INVENTAIRES_INPUT_FILE`, `INVENTAIRES_OUTPUT_DIR`, `INVENTAIRES_DATE_FORMAT`, `INVENTAIRES_CSV_STRICT`, `INVENTAIRES_MAKE_CA` et `INVENTAIRES_AUTO_RUN`. Les autres options reprennent les clés de configuration.

Modes d'exécution et flags internes

Le script expose des flags globaux :

- `DEBUG_MODE` (défaut `FALSE`) : warnings affichés en continu et logs détaillés.
- `BENCHMARK_MODE` (défaut `FALSE`) : chronométrage des blocs de calcul.
- `CLEAN_ENVIRONMENT` (défaut `FALSE`) : purge de l'environnement avant lancement (mode expert).

Le lancement automatique est contrôlé via `INVENTAIRES_AUTO_RUN` (défaut `TRUE`).

Contrat d'entrée

`data/observations.csv` (ou `.txt/.tsv`) avec colonnes obligatoires `site,date,visite_id,espece` et optionnelle `placette`.

Règles : visite distincte `date + visite_id` (et `site` en multi-sites), parsing date strict, déduplication de la clé observation.

Audit CSV

Sorties d'audit :

- `results/ICR/ICR_00_csv_conformite_report.csv`
 - `results/ICR/ICR_00_csv_conformite_problems.csv` (si anomalies)
- En mode strict, toute non-conformité est bloquante.

Logging systématisé

Chaque exécution génère un fichier log horodaté dans le répertoire `logs/` du projet.

Fonctions de logging

- `setup_logging(base_dir, prefix)` : Initialise l'environnement `.log_env` et crée le répertoire `logs/` ; appelée au démarrage
- `log_message(level, ...)` : Fonction centrale avec gestion intelligente des format strings
- `log_info(...)` : Wrapper niveau INFO
- `log_debug(...)` : Wrapper niveau DEBUG
- `log_warning(...)` : Wrapper niveau WARN (affiche aussi en stderr)
- `log_header(script_name, script_version)` : Affiche l'en-tête du script avec métadonnées
- `log_section(title)` : Affiche un titre de section avec délimiteurs

Format et contenu

- **Format des entées** : `[YYYY-MM-DD HH:MM:SS] [LEVEL] message`
- **Nom du fichier** : `logs/ICR_YYYYMMDD_HHMM.log`
- **Contenu** : En-tête du script, métadonnées (timestamp, R version, working dir), progression du pipeline, manifeste final des livrables

Organisation thématique des sorties

Les résultats sont organisés selon une hiérarchie prédéfinie sous `results/ICR/` :

```
results/ICR/
+-- logs/
|   '-- ICR_YYYYMMDD_HHMM.log
+-- 00_data_quality/
|   +-- ICR_00_csv_conformite_report.csv
|   '-- ICR_00_csv_conformite_problems.csv (si anomalies)
+-- 01_richesse/ (réservé pour extensions)
+-- 02_completude_repr/ (réservé)
+-- 03_frequences/ (réservé)
+-- 04_spatial/ (réservé)
+-- 05_temporal/ (réservé)
+-- 06_metrics/
|   +-- ICR_donnees_preparees.csv
|   +-- ICR_resume_tous_sites.csv
|   '-- ICR_metrics_pertinence_tous_sites.csv
+-- comparisons/
|   +-- ICR_comparaison_completude_sites.png
|   +-- ICR_comparaison_ir_sites.png
```

```
| +-- ICR_metrics_pertinence_heatmap_sites.png
| '-- ICR_metrics_pertinence_score_sites.png
'-- sites/
    +-- <site_name>/
    | +-- ICR_01_courbe_temps_especes.csv
    | +-- ICR_02_tee_ir.csv
    | +-- ICR_03_frequence_especes.csv
    | +-- ICR_04_resume_site.csv
    | +-- ICR_07_metrics_pertinence.csv
    | +-- ICR_01_richesse_par_visite_et_cumul.png
    | +-- ICR_02_courbe_temps_especes_hyperbole.png
    | +-- ICR_03_tee_ir.png
    | +-- ICR_04_histogramme_frequences.png
    | +-- ICR_07_metrics_pertinence_dashboard.png
    | +-- ICR_05_modeles.csv (si modèles activés)
    | +-- ICR_06_occupation_spatiale.csv (si placette)
    | +-- ICR_05_temporel_vs_spatial.png (conditionnelle)
    | '-- ICR_06_CA_placettes_especes.png (si vegan + placette)
    '-- <other_site_name>/
        '-- ...
```

Journalisation et intégrité des sorties

La journalisation est réalisée en console via `log_info()`, `log_debug()` et `log_warning()`.

En fin de pipeline, `log_output_manifest()` contrôle les livrables avec statuts : OK, MANQUANT, OPTIONNEL, NON_GENERE.

Le script supprime automatiquement tout `Rplots.pdf` parasite généré pendant l'exécution (niveau site et global).

Livrables

Global

- **Métriques** (06_metrics/) : ICR_donnees_preparees.csv, ICR_resume_tous_sites.csv, ICR_metrics_pertinence_tous_sites.csv.
- **Comparaisons** (comparisons/) : ICR_comparaison_completude_sites.png, ICR_comparaison_ir_sites.png, ICR_metrics_pertinence_heatmap_sites.png, ICR_metrics_pertinence_score_sites.png.

Audit CSV : rapport de conformité et liste des anomalies dans 00_data_quality/.

Logs : ICR_YYYYMMDD_HHMM.log (dans logs/).

Par site (sites/<site_name>/)

Fichiers CSV par site : courbe temps-espèces, TEE/IR, fréquences, résumé de site et métriques de pertinence, avec les graphiques PNG associés.

Sorties conditionnelles : ICR_05_modeles.csv, ICR_06_occupation_spatiale.csv, ICR_05_temporel_vs_spatial.png, ICR_06_CA_placettes_especes.png.

Flux d'exécution

`run_analysis(CONFIG)`

```

-> validate_config()
-> resolve_input_file()
-> read_delim_auto()
-> audit_csv_conformity()
-> export_csv_conformity_report()
-> prepare_data()
-> for each site: analyze_site()
    -> calculs cumul/TEE/frequences/spatial
    -> modeles lineaire/hyperbolique
    -> metriques scientifiques
    -> exports CSV/PNG
-> consolidation multi-sites
-> graphiques globaux
-> log_output_manifest()

```

Dépendances

Requises : `dplyr`, `tidyr`, `ggplot2`, `purrr`, `readr`, `stringr`, `forcats`, `tibble`, `scales`, `gridExtra`.

Optionnelles : `minpack.lm` (hyperbolique), `vegan` (CA/AFC).

Améliorations techniques (v1.4)

Phase 1 : Fiabilisation

- Détection automatique du délimiteur (CSV/TSV/TXT)
- Parsing flexible des dates via format configurable
- Déduplication multi-clé : (`site`, `placette`, `date`, `visite_id`, `espece`)
- Gestion granulaire des erreurs CSV (colonne manquante, type invalide, etc.)

Phase 2 : Performance

- Optimisation du modèle hyperbolique : `minpack.lm::nlsLM` avec détection de convergence
- Calculs vectorisés par site (pas de boucle implicite)
- Mémorisation des graphiques `ggplot2` avant export PNG
- Cache des analyses de CA/AFC conditionnelle

Phase 3 : Graphiques et visualisations

- Cartes de chaleur multi-sites (heatmap) avec échelle de couleur
- Tableaux de bord par site (7 graphiques dans une grille)
- Comparaisons visuelles de complétude (barplot multi-sites)
- Analyses de CA/AFC si `vegan` disponible et placette présente

Phase 4 : Industrialisation

1. **Configuration centralisée** : `get_embedded_config()` avec 14+ paramètres
2. **Logging systématisé** : `setup_logging()` + fonctions `log_*`() avec fichiers horodatés
3. **Organisation thématique** : hiérarchie logique /sites/, /06_metrics/, /00_data_quality/, /comparisons/

4. **Métriques avancées** : calcul de pertinence scientifique, dashboards analytiques, manifeste final

Limites connues

- Sans `placette`, pas d'analyse spatiale.
- Sans `minpack.lm`, pas d'asymptote hyperbolique.
- Si `nb_visites < min_visits_for_model`, pas de modélisation.
- En mode strict, un CSV non conforme bloque le pipeline.

Auteur	Eddy Boite
Dépôt GitHub	eddyboite-nat/myco_apps_releases
Branche	main
Version script	1.1
Date de ce document	9 juillet 2026

Pour toute évolution du script, ouvrir une issue dans le dépôt GitHub ou documenter les changements dans le journal `CHANGELOG.md` du projet.